



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

第 132 回 碩士學位論文

指導教授 文 鎭 宇

컨테인먼트형 데이터센터의 최적
열환경을 위한 적응형 제어알고리즘 개발
및 성능평가

Development and Performance Evaluation of
Adaptive Control Algorithm for Optimal Thermal
Environment in the Containment-type Data Center

中央大學校 大學院
建築學科 建築環境計畫專攻
崔 榮 宰

2020年 2月

컨테인먼트형 데이터센터의 최적
열환경을 위한 적응형 제어알고리즘 개발
및 성능평가

Development and Performance Evaluation of Adaptive
Control Algorithm for Optimal Thermal Environment in
the Containment-type Data Center

이 論文을 碩士學位論文으로 提出함

2020年 2月

中央大學校 大學院
建築學科 建築環境計畫專攻
崔 榮 宰

崔榮宰의 碩士學位論文으로 認定함

審査委員長 _____ ⑩

審査委員 _____ ⑩

審査委員 _____ ⑩

中央大學校 大學院

2020年 2月

목 차

제 1 장 서 론	1
1.1 연구의 배경 및 목적	1
1.2 연구의 범위 및 방법	5
제 2 장 이론 고찰	8
2.1 개요	8
2.2 데이터센터 열환경 제어 기술 동향	8
2.2.1 데이터센터 개요	8
2.2.2 데이터센터 공조제어시스템	12
2.2.3 관련 연구 및 기술 동향	17
2.3 소결	26
제 3 장 데이터센터 CFD 모델링	28
3.1 개요	28
3.2 시스템 구성	29
3.3 CFD 모델링	31
3.3.1 실시간 분석을 위한 통합 환경 구축	31
3.3.2 대상 모델링 계획	32
3.3.3 경계조건 설정	34
3.3.4 CFD 모델링 분석	36
3.4 소결	42

제 4 장 적응형 제어알고리즘 개발	44
4.1 개요	44
4.2 냉매 유량 예측모델 개발	47
4.2.1 입력 변수 설정 및 데이터 구축	47
4.2.2 예측모델 개발	52
4.3 적응형 제어알고리즘 개발	58
4.3.1 보정인자 설정	58
4.3.2 제어알고리즘 구축	59
4.4 소결	62
 제 5 장 적응형 제어알고리즘 성능평가	 64
5.1 개요	64
5.2 냉매 유량 예측모델 성능평가	65
5.2.1 초기 예측모델 성능 평가	65
5.2.2 예측모델 최적화	66
5.3 적응형 제어알고리즘 성능평가	69
5.3.1 보정인자 최적화	69
5.3.2 적응성 성능평가	74
5.4 소결	92
 제 6 장 결 론	 94
 참고문헌	 97

국문초록	103
------------	-----

ABSTRACT	105
----------------	-----

표 목 차

Table 1. 데이터센터 IT 장비 배치 별 분류	11
Table 2. ASHRAE 권장 데이터센터 실내 환경	12
Table 3. 데이터센터 냉각방식	14
Table 4. 국내 데이터센터 현황	19
Table 5. 국외 데이터센터 현황	19
Table 6. 국내 데이터센터 공조제어시스템 및 제어법 선행연구	22
Table 7. 국외 데이터센터 공조제어시스템 및 제어법 선행연구	23
Table 8. 시스템A, B의 경계조건 입력	36
Table 9. 시스템A, B의 온도 분석 위치	37
Table 10. 시스템A 온도분포도	39
Table 11. 시스템B 온도분포도	40
Table 12. 시스템A & 시스템B 기류 흐름도	41
Table 13. 시스템A 시뮬레이션 계획	50
Table 14. 데이터 전처리 기법	52
Table 15. 활성화 함수의 종류	54
Table 16. 인공신경망 적용 함수	55
Table 17. 인공신경망 초기 모델	57
Table 18. 인공신경망 구조별 Cv(RMSE)	69
Table 19. 보정인자 최적화 시뮬레이션 개요	70
Table 20. 보정인자($\alpha=1.0, 1.2, 1.4$) 에 따른 급기온도 및 오차	72
Table 21. 보정인자($\alpha=1.6, 1.8, 2.0$) 에 따른 급기온도 및 오차	72
Table 22. 적응성 평가를 위한 시스템B 시뮬레이션 개요	76
Table 23. 시스템 및 Case 별 최대 온도 오차 절댓값	78
Table 24. 시스템 및 Case 별 RMSE	79
Table 25. 비적응형 제어알고리즘 케이스별 5시간 단위 RMSE	80

그림 목차

Fig. 1 데이터센터 에너지 소비비율	2
Fig. 2 연구 과정 흐름도	7
Fig. 3 데이터센터의 구성	9
Fig. 4 냉각 시스템 모델링 범위	30
Fig. 5 시스템A 구성도	33
Fig. 6 시스템B 구성도	33
Fig. 7 인공신경망의 개념 및 구조	45
Fig. 8 최종 데이터세트 구성	51
Fig. 9 초기 인공신경망 구조	56
Fig. 10 데이터세트의 구성	56
Fig. 11 제어 사이클 개념도	60
Fig. 12 적응형 제어알고리즘	61
Fig. 13 학습률 최적화에 따른 Cost 값 변화	67
Fig. 14 보정인자 변화에 따른 CRAC 토출 공기 온도 변화	73
Fig. 15 보정인자 변화에 따른 오차 절댓값 변화	73
Fig. 16 ON&OFF 시스템 설정온도 고정 & 풍량 고정	84
Fig. 17 ON&OFF 시스템 설정온도 변경 & 풍량 고정	84
Fig. 18 ON&OFF 시스템 설정온도 고정 & 풍량 변경	85
Fig. 19 ON&OFF 시스템 설정온도 변경 & 풍량 변경	85
Fig. 20 비적응형 제어알고리즘 설정온도 고정 & 풍량 고정	86
Fig. 21 비적응형 제어알고리즘 설정온도 변경 & 풍량 고정	86
Fig. 22 비적응형 제어알고리즘 설정온도 고정 & 풍량 변경	87
Fig. 23 비적응형 제어알고리즘 설정온도 변경 & 풍량 변경	87
Fig. 24 적응형 제어알고리즘 설정온도 고정 & 풍량 고정	88

Fig. 25 적응형 제어알고리즘 설정온도 변경 & 풍량 고정	88
Fig. 26 적응형 제어알고리즘 설정온도 고정 & 풍량 변경	89
Fig. 27 적응형 제어알고리즘 설정온도 변경 & 풍량 변경	89
Fig. 28 Case 1에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차	90
Fig. 29 Case 2에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차	90
Fig. 30 Case 3에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차	91
Fig. 31 Case 4에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차	91

제 1 장 서 론

1.1 연구의 배경 및 목적

2016년, 다보스 포럼(WEF: World Economic Forum, 2016)에서 4차 산업혁명에 대한 이슈가 등장한 후 전 세계적으로 기계 자동화 및 데이터 처리와 관련된 신기술에 대한 중요성이 강조되고 있다. 통계청에서는 2017년 하반기 연구보고서에서 자율주행차, 로봇, 인공지능(Artificial Intelligence, AI), 빅데이터(Big Data), 사물인터넷(Internet of Things, IoT), 블록체인(Blockchain) 등을 4차 산업혁명의 주요 테마 및 기술로 선정하였다¹⁾. 해당 테마들은 모두 데이터 기반의 기술들이며 이와 관련된 산업들이 급증하고 있는 추세이다.

2022년 국내 인터넷 통신량은 2015년 대비 2배로 증가할 전망이고 전 세계 모바일 데이터 사용량은 2018년 36억 명에서 2025년 50억 명으로, 사물인터넷 연결망은 약 3배 증가할 것으로 예상된다²⁾. 이와 같은 데이터 처리의 수요 증가에 따라 관련 장비의 성능과 처리능력 또한 급격히 발전하였으며, IT 장비들을 통합적으로 관리 및 유지하는 데이터센터(Data Center)에 대한 관심이 증가하고 있다.

데이터센터는 전 세계 전력 사용량의 2%를 차지하며 이는 2030년경 8% 까지 증가할 것으로 예상된다³⁾. 또한 CO₂ 배출 증가량은 정보통신 분야에서 가장 높은 것으로 조사되었다⁴⁾. 데이터센터는 내부부하 중심

1) 박승민. (2017). 4차 산업혁명 주요 테마 분석. 통계청 2017년 하반기 연구 보고서 제 3권.

2) George Kamiya. (2019. 11). data centres and data transmission networks. <https://www.iea.org/tcep/buildings/datacentres/>

3) Naomi Xu Elegant. (2019. 11). The Internet Cloud Has a Dirty Secret. <https://fortune.com/2019/09/18/internet-cloud-server-data-center-energy-consumption-renewable-coal/>

건물(Internal Load Dominated Building)로써 고밀도 에너지 다소비 건물군에 속한다⁵⁾. 데이터센터의 에너지 소비비율은 <그림 1>과 같이 냉각 시스템 50%, IT 장비 26%, 전력 장비 15%, 기타 9%로 구성되며 IT 장비보다 냉각 시스템에 사용되는 에너지 비율이 높다⁶⁾. IT 장비는 IT 부하에 따라 발열이 생기며 장비별로 정해진 기준치 이상의 열이 발생하면 작동이 중지된다. IT 장비가 설치되는 서버실은 IT 장비, 조명, 각종 설비에 의한 내부발열만이 존재하며 일정 범위의 온도와 습도로 유지되어야 한다. 따라서 지속적인 모니터링을 통해 냉방을 무중단으로 실시해야 하며 변화하는 냉방부하를 실시간 제어를 통해 해결해야한다. 또한 데이터센터의 에너지 효율을 높이기 위해서는 냉각 및 공조 시스템에 대한 효율성 향상이 필수적이며 이는 IT 장비의 효율화와 함께 고려되어야 한다.




Fig. 1 데이터센터 에너지 소비비율

-
- 4) Whitehead, B., Andrews, D., Shah, A., & Maidment, G. (2014). Assessing the Environmental impact of data centres. Part 1: Background, energy use and metrics, Building and Environment, Vol. 82, 151-159.
- 5) 조진균 (2008). 고밀도 데이터센터의 공조효율 및 에너지성능 개선을 위한 공조시스템 계획방법 연구, 연세대학교 박사학위논문, p.1.
- 6) Info-Tech Research Group. (2007). Top 10 Energy-Saving Tips for a Greener Data Center. Operate & Optimize Info-tech Advisor Premium.

2011년 11월 한국IT서비스산업협회(ITSA)에서는 데이터센터의 에너지 절감과 비용의 감소, 경쟁력 강화를 위하여 그린데이터센터 인증위원회를 구성하였으며 그린데이터센터 인증제를 추진하였다. 인증제에 포함된 평가 항목은 총 5가지로 DC 인프라 효율성(PUE), DC 에너지 효율관리 설비, DC 그린활동, IT 장비 효율성, 건물의 친환경성, DC 생산성을 평가한다⁷⁾. 이 중 가장 큰 비율을 차지하는 것은 DC 인프라 효율성으로써 PUE(Power Usage Effectiveness)로 측정된다. PUE란 데이터센터 에너지 효율 측정 지표로써 총 데이터센터 소비 전력량에 대한 IT 장비의 전력 소비량이다. PUE가 낮을수록 에너지 효율이 높은 것을 의미하며 1에 근접하도록 하는 것이 데이터센터 에너지 효율설계의 궁극적인 목표이다.

$$PUE = \frac{\text{데이터센터 전체 전력소비량}}{\text{IT장비 전력소비량}} \dots\dots\dots (\text{식 } 1)$$

데이터센터 에너지 소비 비율과 PUE에 따라 냉각 시스템의 효율화는 더욱 강조된다. 방송통신위원회(Korea Communications Commission, KCC)에서 발행한 그린데이터센터 구축 지침⁸⁾에서는 공조 부문의 운영, 관리 방안, 공조기의 선택, 기기배치 등에 대한 내용을 제시하고 있다. 하지만 물리적 시스템의 기계적 결함 관리 방안 및 설비 선택, 서버의 배치 등에 대한 내용을 주로 다루고 있는 반면 소프트웨어 측면의 제어방안에 대해서는 언급하고 있지 않다. 최근 신설되는 데이터센터의 경우 이코노마이저(Economizer) 기술을 도입하고 있지만 외기 도입 조건에 해당하는 일수가 많지 않은 국내에서는 선진 데이터센터에 비해 활용도가 낮다. 또한 한국IT서비스산업협회에 따르면 국내 데이터센터의

7) 정산진, 김문구. (2013). 그린 데이터센터 표준화 및 인증제 동향. 한국정보통신기술협회.
8) 방송통신위원회 국립전파연구원. (2012). 그린 데이터 센터 구축 지침. 방송통신표준 KCS.KO-09.0065.

약 36%는 리모델링 및 확장의 계획이 없는 것으로 조사되었으며⁹⁾ 이는 보수 공사 진행시의 높은 비용과 서버 운영 중단 문제 때문인 것으로 분석되었다. 따라서 기존 냉방 시스템에도 적용이 가능한 에너지 운영 및 제어 측면에서의 효율화 방안이 필요한 실정이다.

기존 서버실 온도제어는 관리자가 실내 환경에 대한 모니터링을 통해 수동적인 방식으로 시스템 설정을 변경하는 방식이었다. 하지만 이는 관리자의 경험적인 판단에 의해 결정되는 방식이며 수동 제어로 인한 오류 발생 위험에 따라 시스템의 설정온도를 권장 온도보다 낮게 유지하고 있다. 또한 자동제어 시스템의 경우에도 변화하는 외부 환경에 따라 설정 값을 변경시켜야 하며 지속적인 최적화 과정이 필요하다. 이러한 상황은 잦은 시스템 가동 상태의 변경, 경험에 의존한 시스템 최적화로 인해 최적의 실내 열환경 제공을 어렵게 하며 비효율적인 에너지 소비를 야기시킨다.

따라서 본 연구의 목적은 데이터센터의 최적 열환경을 안정적으로 제공하기 위해 자동제어가 가능한 적응형 제어알고리즘(Adaptive Control Algorithm)을 개발하는 것이다. 적응형 제어알고리즘이란 기존의 냉방 시스템에 기계설비적 보수 없이 제어 수단으로 적용되어 최적 온도제어를 가능하게 하는 알고리즘으로, 각기 다른 데이터센터의 열환경에 대한 적응 기능을 내포한 것을 의미한다. 적응형 제어알고리즘은 온도제어를 가능하게 하는 대상에 대한 예측모델을 포함한다. 해당 예측모델은 학습 기능을 통해 새로운 환경에 대한 적응을 실시한다. 안정적인 최적 열환경 제공 및 자동제어는 관리자의 수동 조절에 대한 위험 부담을 줄여주며 불필요한 에너지 소비를 최소화 한다. 이에 따라 적응형 제어알고리즘은 보편화된 제어 수단 및 에너지 효율 방안으로써의 의미와 데이터센터

9) 미래창조과학부. (2015). 데이터센터 산업 육성을 위한 기반조성 연구·조사. 방송통신정책연구. 15-진흥-003.

뿐만이 아닌 건축물의 최적 열환경 제공 방법의 기초를 확립하는 것에 의의를 가진다.

1.2 연구의 범위 및 방법

본 연구의 목적은 적응형 제어알고리즘 및 제어알고리즘에 포함되는 냉매 유량 예측모델을 개발하는 것으로써 개발 과정에 필요한 이론고찰, 통합 환경 구축, 데이터 취득 수단 및 방법, 그리고 개발된 예측모델 및 알고리즘의 성능평가를 연구 범위에 포함한다. 연구 범위 및 방법은 <그림 2>로 요약된다.

데이터센터는 단일 용도로 사용되는 특수목적 시설로써 연구 목적에 맞는 공조시스템과 제어시스템의 동향 및 기술 분석이 선행되어야 한다. 선행된 이론고찰을 바탕으로 연구 대상 선정 및 연구 계획을 수립하였다.

예측모델 개발을 위한 환경 변수 데이터 취득 및 적응형 제어알고리즘의 성능분석을 위하여 전산유체역학(Computational Fluid Dynamics, CFD) 프로그램을 통해 시스템A, 시스템B 두 가지 컨테이너먼트형 데이터센터를 모델링하였다. 해당 모델은 시뮬레이션을 실시하여 결과 분석을 통해 실제 데이터센터와의 온도, 기류 흐름에 대한 유사성을 비교한다.

냉매 유량 예측모델과 적응형 제어알고리즘은 컴퓨터 프로그래밍 언어를 사용하여 개발한다. 먼저 냉매 유량 산출을 위한 입력 변수를 선정하고 시스템A 데이터센터 모델의 시뮬레이션을 통해 필요한 데이터를 취득한다. 데이터는 전처리과정을 통해 예측모델에 학습되며 이를 활용하여 초기 예측모델을 구축한다. 적응형 제어알고리즘은 개발된 예측모델을 내포하며 실시간 제어 상황에서 예측 값에 대한 오차를

보정해 나갈 수 있도록 구성된다.

초기 예측모델은 정확도를 평가하는 통계적 지표를 이용하여 성능평가를 실시하며 최적화 과정을 통해 최종 냉매 유량 예측모델을 정의한다. 적응형 제어알고리즘 또한 최적화 과정을 거친 후 시스템B 데이터센터 모델에 적용되어 적응성 평가를 실시한다. 이후 기존 제어시스템인 ON&OFF 시스템 및 예측모델이 적용되었으나 적응의 기능은 제외된 제어알고리즘과의 비교분석을 통해 개선된 점에 대한 분석을 실시한다.




Fig. 2 연구 과정 흐름도

제 2 장 이론 고찰

2.1 개 요


본 장에서는 연구에 필요한 이론적 지식 및 연구 방향을 설정하기 위하여 데이터센터와 관련 이론에 대하여 고찰하였다. 데이터센터의 정의와 특징 및 적용되는 공조제어시스템의 종류를 파악하였으며 실제 데이터센터에 사용되는 공조제어시스템 현황 조사를 실시하였다. 이후 관련 연구 및 최신 기술 동향에 대한 파악 및 이를 바탕으로 연구의 방향성 및 연구 대상을 설정하였다.

2.2 데이터센터 열환경 제어 기술 동향

2.2.1 데이터센터 개요

한국 IT 산업협회에서는 데이터센터를 서버, 스토리지 등의 ICT (Information and Communications Technologies) 장비를 중앙집중식으로 집적시키고 운영 및 관리에 필요한 장비의 통합 관리를 통해 24시간 365일 무중단으로 운영하는 시설로 정의 한다¹⁰⁾. 운영 및 관리에 필요한 시설에는 전기, 항온항습실, 발전기, 소방, 안전 등이 포함되며 <그림 3>과 같다.

10) 미래창조과학부. (2015). 데이터센터 산업 육성을 위한 기반조성 연구·조사. 방송통신정책연구. 15-진흥-003.



* UPS: Uninterruptible Power Supply

* PDU: Power Distribution Unit

Fig. 3 데이터센터의 구성

통신 부문의 데이터센터는 인터넷 데이터센터(Internet Data Center, IDC), 클라우드 서비스를 위한 데이터센터는 클라우드 데이터센터(Cloud Data Center, CDC)로 구분된다. 클라우드 데이터센터는 인터넷 데이터센터보다 유연성(High Flexibility), 고밀도(High Density), 관리 최적화(Management Optimization) 등 더욱 진보된 기술로 서비스에 최적화 되어있다. 또한 목적에 따라 고객 서비스용의 데이터센터와 기업을 대상으로 하는 상용 데이터센터로 분류된다.

데이터센터의 규모는 면적대비 IT 서버룸(IT Server Room)이 차지하는 면적을 바탕으로 소규모 데이터센터, 중규모 데이터센터, 대규모 데이터센터로 구분된다. 소규모 데이터센터는 IT 서버룸 면적이 93m^2 이하로 5~20개의 랙(Rack)으로 구성되며 7~100 kW의 전력을 소비한다. 중규모 데이터센터의 IT 서버룸 면적은 $93\sim 465\text{m}^2$ 이고 랙은 20~100개가 설치되며 전력소비량은 28~500 kW 이다. 대규모 데이터센터는 465m^2 이상의 IT 서버룸 크기에 100개 이상의 랙이 설치되며 200 kW이상의 전력을 소비 한다¹¹⁾.

데이터센터의 구조는 IT 서버의 배치 방식 및 관련 시설과의 구성에 따라 세 가지로 분류되며 형태 및 특징은 <표 1>과 같다. 전산실 개방형(Open-Architecture)은 랙이 별도의 차폐 시설 없이 전면과 후면이 마주보도록 열(Row)을 지어 배치된 형태이다. 일반적으로 이중마루 시스템에 구축되며 다수의 향온향습기(CRAC)가 서버룸의 환경을 통합적으로 제어한다. 국지적 열 발생 문제인 핫스팟(Hot Spot)에 대한 위험이 높으며 난류에 의해 CRAC 회수 공기 온도가 내려가 냉방 효율이 감소한다. 또한 서버실 환경을 구역 별로 제어하기 어렵다는 단점이 있다.

전산실 개방형의 단점을 보완하고 냉각 효율을 높이기 위하여 컨테인먼트(Containment) 시스템이 등장하였다. 컨테인먼트는 찬 공기가 유입되는 냉복도(Cold Aisle), 서버를 식힌 뜨거운 공기가 배출되는 열복도(Hot Aisle)를 독립 공간으로써 차폐한 형태이다. 컨테인먼트 내부에는 CRAC이 함께 설치되며 내부 공기는 서버룸의 공기와 혼합되지 않아 냉각 효율을 극대화 시킬 수 있다. 또한 IT 부하에 따른 컨테인먼트 단위의 실내 환경 제어가 가능하여 전산실 개방형보다 에너지 효율에 유리해 신설되는 데이터센터에 적용률이 높다.

모듈러(Modular) 데이터센터는 일체형 데이터센터로도 불리며 IT 장비, 전력, 냉각 시스템이 하나의 모듈 안에 모두 집적된 형태이다. 단일 모듈로도 구동이 가능하며 이동성이 높고 증설에 유리하다. 최근 다양한 포맷으로 연구가 다양하게 진행되고 있으나 IT 용량에 한계가 있고 제작비용이 높다는 단점이 있다.

IT 서버는 무중단으로 운영되기 때문에 고장의 위험에 노출되어 있으며 고온에 노출될 경우 장비가 정지하는 문제를 불러일으킨다. ASHRAE (American Society of Heating, Refrigerating and Air-Conditioning

11) 한국IT서비스산업협회, (2008). 데이터센터의 정의와 분류체계.

Engineers)에서는 <표 2>과 같이 IT 서버 가동 시의 권장 환경 조건을 제시하고 있으며 적용수준 및 적용용도에 따라 4단계로 구분하고 있다¹²⁾. 본 연구에서는 가장 엄격한 조건인 Class 1을 실내 환경 조건으로 채택한다.

Table 1. 데이터센터 IT 장비 배치 별 분류

구 분	형 태	특 징
전산실 개방형 (Open-Architecture)		• 서버룸에 랙이 열(Row)을 지어 배치된 형태 • 전면과 후면을 마주보도록 배치 • 향온향습기가 서버룸 전체를 공조
컨테인먼트 (Containment)		• 냉복도(Cold Aisle)과 열복도(Hot Aisle)을 구분지어 차폐 • 내부에는 랙, 향온향습기, UPS 등을 포함 • 전산실과 공기가 혼합되지 않음
모듈러 (Modular)		• 일체형 데이터센터로도 불리며 IT, 전력, 냉각 시스템을 하나의 모듈 안에 모두 포함 • 이동성 및 확장성이 높음 • IT 용량에 제한이 있어 일시적 요구, 소규모 데이터센터에 유리

12) ASHRAE. (2010) Green Tips for Data Centers. ASHRAE Datacom Series 10.

Table 2. ASHRAE 권장 데이터센터 실내 환경 (ASHRAE Green Tips for Data Centers, ASHRAE Datacom Series 10, 2010)

구 분	건구온도 (℃)	습도 범위	최대 노점온도 (℃)
Class 1	18~27	5.5~15℃ & ≤ 60% RH	17
Class 2	18~27	5.5~15℃ & ≤ 60% RH	21
Class 3	-	-	28
Class 4	-	-	28

2.2.2 데이터센터 공조제어시스템¹³⁾¹⁴⁾

데이터센터의 공조시스템은 서버룸의 유지 및 관리와 직결되어 있으며 데이터센터 전체 전력 소비량의 약 50%를 차지하는 만큼 중요성이 높다. 공조시스템은 서버발열 제거를 위해 항상 운영되며 공조공기를 서버로 전달하는 공기분배시스템과 공기를 냉각시키는 설비에 열원을 공급하는 열원 시스템으로 구분된다. 열원 시스템은 전산실의 발열을 외부로 방출시키는 냉각 사이클을 모두 포함하며 냉각탑, 냉동기, CRAC (Computer Room Air Conditioner), CRAH (Computer Room Air Handler) 등이 이에 해당된다. 데이터센터에 주로 사용되는 시스템은 <표 3>과 같이 크게 5가지로 분류된다.

먼저, 실내형 공랭자급식 시스템은 CRAC에 통풍관이 직접 연결된 형태이다. 전산실 내부에 냉각 사이클이 모두 포함되며 흡수된 열기는 통풍관을 통해 외부로 직접 방출된다. 공급공기는 외부에서 제공되어야 하며 최대 15 kW의 용량 제한이 있다. 국내에서는 많이 사용되지 않는 시스템이다.

13) 조진균. op. cit. p.31.

14) Tony Evens. (2004). The Different Types of Air conditioning Equipment for IT Environments. APC White Paper, p.59.

공랭식 DX (Direct Expansion) 시스템은 일반적인 에어컨 시스템과 동일하다. 냉각 사이클은 실내기와 실외기에 의해 구성되며 전산실 내부의 발열은 실외에 설치된 건식 냉각기에 의해 외부로 방출된다. 열전달은 냉매에 의해 이루어지며 일반적으로 7~200 kW 규모의 IT환경에서 광범위하게 사용된다. 하나의 냉각기로 다수의 CRAC을 지원할 수 있으나 실내기와 실외기의 거리가 멀어지면 신뢰성과 경제성이 감소한다.

글리콜 냉각 시스템은 공랭식 DX 시스템과 유사하지만 냉각 사이클이 모두 실내에 위치하며 콘덴싱 코일(Condensing Coil) 대신 열교환기가 설치된다. 열교환기에서 IT 발열은 글리콜 용액으로 전달되며 순환되는 용액은 실외의 건식 냉각기를 통해 외부로 열을 방출한다. 글리콜 용액은 열전달 능력이 뛰어나 공랭식 DX 시스템보다 배관 거리를 길게 설계할 수 있으며 신뢰도가 높다. 또한 외기의 기온이 낮을 경우 글리콜 용액은 10℃ 이하로 유지될 수 있기 때문에 외기 냉방 시스템인 이코노마이저(Economizer) 모드를 사용할 수 있다. 대부분의 냉방 에너지는 압축과정에서 발생하므로 에너지를 거의 소비하지 않고 냉동 효과를 얻을 수 있다¹⁵⁾.

수냉식 시스템은 CRAC에 냉각탑이 결합된 형태이다. 모든 냉각 사이클이 CRAC 내부에 구성되며 전산실 발열은 열교환기에서 냉각수로 전달되어 실외에 설치된 냉각탑으로 전달된다. 하나의 냉각탑에 여러 대의 CRAC이 연결될 수 있으나 초기 비용 및 관리 비용이 높다.

중앙 냉수식 시스템은 수냉식 냉수 시스템으로도 불리며 전산실 에어컨인 CRAC 대신 전산실 공조시스템인 CRAH 유닛을 사용한다. 시스템은 CRAH, 냉동기, 냉각탑으로 구성되며 전산실의 발열된 공기는

15) 원종연 (2004). 외기냉수냉방 시스템의 에너지 절약효과에 관한 연구, 중앙대학교 석사학위논문, p.9.

CRAH를 통해 냉수로 열을 전달하고 냉수는 냉동기에서 또 다른 냉수에 열을 전달하여 실외로 열을 배출한다. 대형 시스템에서 많이 사용되며 냉동기와 냉각탑 사이의 열전달 매체는 글리콜로 대체될 수 있다. 하나의 냉동기는 여러 대의 CRAH를 지원할 수 있으며 신뢰도가 높다.

Table 3. 데이터센터 냉각방식 (Tony Evans, 2004)

구 분	개념도 및 특징	
실내형 공랭자급식 시스템		
	• 냉각 사이클에 필요한 유닛들을 모두 실내에 포함 • CRAC에 통풍관이 연결되어 외부로 열 방출 • 최대 15 kW의 용량 제한이 있음	
공랭식 DX (Direct Expansion) 시스템		
	• 중소형 전산실용으로 많이 사용됨 • 실외기와 실내기로 나누어져 냉각 사이클 가동 • 전산실의 열은 냉매로 흡수되어 외부로 방출	

글리콜 냉각 시스템	• CRAC에 건식 냉각기가 연결됨 • 글리콜은 냉매와의 열교환을 통해 외부로 배출 • 하나의 건식 냉각기로 여러 대의 CRAC 연결 가능
수냉식 시스템	• 수냉식 CRAC에 냉각탑이 결합됨 • CRAC 내부에 모든 냉각 사이클 포함 • 하나의 냉각탑으로 여러 대의 CRAC 연결 가능
중앙 냉수식 시스템	• 수냉식 CRAC에 냉각탑이 결합됨 • CRAC 내부에 모든 냉각 사이클 포함 • 하나의 냉각탑으로 여러 대의 CRAC 연결 가능

데이터센터 냉각 에너지 절감을 위해 외기 도입 방식 또한 적극적으로 채택되고 있다. 외기 도입 방식인 이코노마이저(Economizer) 모드는 직접 외기냉방(Direct Air-side Economizer)과 간접 외기냉방(Indirect Air-side Economizer)으로 구분된다.

직접 외기냉방은 외기의 온습도 조건에 따라 도입여부가 결정된다. 여름철과 같이 외기의 온습도 조건이 배기보다 높은 경우 댐퍼는 외기를 도입하지 않도록 제어되고 내부 순환 공기만을 이용하여 공조를 실시한다. 외기의 온도가 배기보다 낮고 설정온도보다 높은 경우에는 100% 외기를 도입하며, 외기 온도가 설정온도 이하인 경우에는 외기와 배기가 혼합되도록 댐퍼를 조절한다. 또한 외기의 습도가 실내 습도에 비해 낮을 경우 별도의 가습을 실시한다. 외기를 직접 도입하기 때문에 불순물을 제거하는 필터의 적용이 필수적이다.

간접 외기냉방은 냉수 열원에 적용되는 외기냉수냉방과 열교환기를 통한 실내 공기 냉각 방식으로 구분된다. 외기 온도가 일정 값 이하일 경우, 외기는 냉동기를 바이패스(Bypass)하여 직접 냉수를 냉각시킨다. 외기에 간접식 증발 냉각기를 이용하여 외부 습기가 실내 공기에 전달되지 않도록 하는 방식이 가장 많이 사용되고 있다¹⁶⁾.

데이터센터 공조제어시스템에 적용되는 제어 알고리즘은 기계적 측면의 공조시스템 외에 시스템 운영방식, 최적 제어 알고리즘 등의 적용으로 효율적인 에너지 운영을 가능하게 한다. 데이터센터의 실내 환경은 IT 부하, IT 장비의 종류, 배치 방법, 실외 환경, 공조시스템 등 다양한 요소의 복합적인 상호작용으로 이루어진다. 따라서 온도 제어 및 관리 시스템은 데이터센터의 구성에 따라 최적화되어 운영되며 단독 운영이 아닌 데이터센터 전체 시설 운영에 포함되어 건물에너지관리시스템

16) 김민휘. (2014). 데이터 센터의 최신 공조시스템과 제어기술. 한국건축친환경설비학회 건축환경설비 8(1), 25-33.

(Building Energy Management System, BEMS)을 통한 통합 관리가 이루어지는 경우가 대부분이다.

데이터센터의 실내 환경 제어는 전산실 및 서버 운영 환경의 모니터링을 기반으로 실시한다. 모니터링 요소로는 실외 온도 및 습도, 전산실 내부의 온도 및 습도, 서버 발열량 등이 있으며 각 데이터센터의 권장 온도 기준에 따라 냉각 시스템의 가동상태가 결정된다.

최적 실내 환경 제공을 위한 제어 대상은 댐퍼 개폐도에 의한 외기 풍량 조절, 냉매 유량 조절에 따른 열교환율의 변화, CRAC 팬 가동률을 통한 풍량 조절, 냉각탑 물 분무량 제어를 통한 증발냉각량의 조절 등 데이터센터에 적용되는 공조시스템에 따라 상이하다. 따라서 데이터센터에 적용되는 실내 환경 제어 시스템 및 알고리즘은 일반화가 어려우며 각 데이터센터의 지리적 위치 및 상황에 맞추어 최적화가 진행되어야 한다.

2.2.3 관련 연구 및 기술 동향

데이터센터는 여러 기업 및 기관의 데이터를 관리하는 시설임에 따라 보안은 데이터센터의 운영에 있어 핵심적인 요소이다. 이에 실제 데이터센터에서 사용되고 있는 공조제어시스템 및 제어 알고리즘과 운영 실태의 파악이 어려운 실정이다. 따라서 본 연구에서는 선행 연구 및 공개된 자료의 조사를 통해 공조제어시스템 적용 현황 및 기술 동향을 파악하였다.

(1) 데이터센터 공조제어시스템 현황

최근 국내에는 대규모 데이터센터가 지속적으로 신설되고 있으며

에너지 효율화를 위하여 다양한 공조제어시스템이 도입되고 있다. 참고 문헌 및 공개된 정보에 의한 국내외 데이터센터 공조제어시스템은 <표 4.5>¹⁷⁾와 같다.

국내 데이터센터 사례 9건 중 공조시스템 채택 비율은 중앙 냉수식 시스템이 가장 높은 것으로 조사되었다. 2010년 이후로는 컨테이너먼트가 적용되고 있으며 외기 냉방 또한 적극적으로 도입되었다. 신기술 및 에너지 효율을 높이는 기술이 적용됨에 따라 2007년 1.79의 PUE에서 2015년에는 1.38까지 감소하였다. <표 4>에는 대체로 PUE가 낮게 조사되었지만 국내 PUE의 평균은 2.66으로 국외에 비해 에너지 효율이 낮은 것이 현실이다¹⁸⁾. 최근에는 부동산 및 비교적 서늘한 기후적 요건으로 인해 강원도 춘천 지역에 다수의 데이터센터가 신설되고 있다. Case 8의 경우 국내 최대 규모의 데이터센터로 외기냉방시스템에 고압 수분무 기능을 추가하여 증발냉각을 통한 냉각 및 가습을 통해 시스템의 장점을 극대화 시켜 PUE 절감을 달성하였다¹⁹⁾.

국외 데이터센터는 국내 데이터센터와는 운영 방식이 상이하다. 글로벌 기업들은 아일랜드, 핀란드, 노르웨이 등 한랭기후에 속한 지역에 데이터센터를 신설하고 있으며 연간 대부분의 기간을 외기냉방시스템으로 공조제어를 실시한다. 기계적 냉각 사이클 또한 존재하나 이는 비상 백업용으로 사용된다. IT 기업을 중심으로 데이터센터 에너지 효율을 위한 연구가 활발히 진행되고 있으며 해수를 이용한 냉각 방식, 해저 데이터센터의 설계 등 다양한 신기술이 적용되고 있는 추세이다.

17) 김재현, 이진영, 조진균. (2013). 그린데이터센터 구현을 위한 가이드라인 연구. 대한설비공학회 하계학술발표대회 논문집, 439-442.

18) 배용진, (2019. 11). 한국은 데이터센터 각축장, 글로벌 기업 속속 들어오는 이유. <http://m.pub.chosun.com/mobile/news/view.asp?cate=C01&mcate=M1002&nNewsNumb=20171026426&nidx=26427/>

19) 연창근, 이진영. (2016). 네이버 데이터센터 ‘각’. 건축환경설비, 10(3), 51-57.

Table 4. 국내 데이터센터 현황

구 분	준공년도	공조시스템	컨테이너먼트	외기냉방	PUE
Case 1	2007	수냉식	○	직접	1.79
Case 2	2007	지역 냉수	-	-	1.78
Case 3	2008	중앙 냉수식	-	-	1.68
Case 4	2009	수냉식	-	-	1.70
Case 5	2010	중앙 냉수식	○	-	1.70
Case 6	2010	-	○	직접	1.40
Case 7	2013	중앙 냉수식	○	직접	1.40
Case 8	2013	중앙 냉수식	○	직접	1.30
Case 9	2015	지역 냉수	○	간접	1.38

Table 5. 국외 데이터센터 현황

구 분	준공년도	공조시스템	컨테이너먼트	외기냉방	PUE
Case A	2009	-	○	직접	1.40
Case B	2009	-	○	-	1.30
Case C	2009	미가동	○	직접	1.20
Case D	2009	미가동	○	직접	1.25
Case E	2011	미가동	○	직접	1.07
Case F	2011	미가동	○	직접	1.22
Case G	2011	미가동	○	직접	1.11
Case H	2011	공랭식	○	-	1.45

(2) 데이터센터 공조제어시스템 선행연구 및 관련 기술

데이터센터의 공조제어시스템 및 제어법과 관련된 연구는 국내외로 다양하게 진행되고 있으며 IT 전문 솔루션 기업에서는 신기술을 접목한 데이터센터 관리 시스템을 제공하고 있다. 선행연구는 “데이터센터 공조시스템(Data Center HVAC System)”, “데이터센터 냉각시스템(Data Center Cooling System)”, “데이터센터 제어(Data Center Control System)” 등의 키워드로 검색하였으며 동향 및 지침 구축과 관련된 연구 논문은 제외하였다.

국내 선행연구 조사 결과는 <표 6>과 같다. 대부분의 연구 자료 및 문헌은 데이터센터 동향, 사례조사, 그린데이터센터 구축 지침에 대한 내용이며 해당 내용은 본 논문에서 제외되었다. 2010년 이전으로 데이터센터의 평가 방법 및 구축에 필요한 객관적 지표 제시에 대한 연구가 진행되었으며 2013년 이후에 에너지 절감을 위한 제어법 연구가 시작되었다. 하지만 CRAC 및 CRAH의 팬 속도 제어에 의한 에너지 절감 방안에 대한 연구, 직접 외기도입 및 간접 외기도입 융합 방식의 최적 제어 알고리즘 등 새로운 기술 도입에 관한 연구는 많이 부족한 실정이며 대부분 현존하는 시스템의 배치 방법 및 설비 효율에 따른 분석이 주를 이루었다.

국외 선행연구의 경우 다양한 공조제어시스템 및 제어법에 대한 연구가 진행되었으며 <표 7>과 같다. 대다수의 연구가 모델 예측 제어(Model Predictive Control, MPC)를 기반으로 한 에너지 절감을 목표로 하였으며 CFD 시뮬레이션을 통하여 성능 분석을 실시하였다. Chen (2012, 2014)은 CPS 체계 구축을 위하여 단순한 온도 선형 예측 모델을 구사하였으며 후속 연구로 해당 예측 모델을 활용하여 팬의 제어를 통해 냉방 에너지의 34%를 절감하였다. Song (2013, 2014)은 인공지능망을 활용하여

데이터센터의 실시간 환경 모니터링을 위한 열환경 예측모델을 개발하였으며, CFD 대비 빠른 속도로 실제 상황에서의 활용 가능성을 확인하였다. Gao (2014)와 Lazic (2018) 또한 인공신경망 및 강화학습을 사용하여 PUE 예측, 적응형 제어알고리즘을 통해 기존 제어시스템에서 탈피하여 신기술에 대한 가능성을 확인하였다. Estebe (2014)는 최적 설정온도 도출 방안에 대한 연구를 통해 TACS (Temperature Adaptive Control Strategy)에 대한 시스템 구성을 제안하였다. Ogawa (2015)는 모듈형 데이터센터에서 외기 도입 시스템을 활용한 MPC 기반 냉각 시스템의 개발을 통해 20%의 에너지를 절감하였다. 이 외에도 클라우드 기반의 통합 제어 시스템 구성, CRAC 팬 제어를 통한 에너지 최적방안 도출 등의 연구가 진행되었다.

연구 동향 조사 결과 국내는 국외에 비해 연구 내용 및 주제가 다양하지 못하고 특정 분야에 한정되어 연구가 진행되고 있었다. 또한 제어법에 있어서 신기술 접목의 흐름이 나타나지 않았으며 대부분의 연구가 현상에 대한 모니터링 및 배치 방법의 변경, 설비의 효율 개선 방안 제시 등 기계적 시스템에서 이루어졌다. 반면 국외의 경우 다양한 분야에서 데이터센터 에너지 절감을 목적으로 연구가 이루어지고 있었다. MPC, 인공신경망, 강화학습 등의 기술을 이용하여 기계적인 해결 방안을 넘어 소프트웨어적인 접근으로 데이터센터 에너지 절감에 대한 연구가 진행되는 추세이며, IoT를 활용한 효율적인 통합 제어시스템과 같은 거시적인 측면에서의 연구 또한 동시에 진행되고 있다.

Table 6. 국내 데이터센터 공조제어시스템 및 제어법 선행연구

저 자	연 도	내 용
Cho J., et al. ²⁰⁾	2006	데이터센터 에너지 소비량에 영향을 미치는 변수에 대한 정량적 분석
Cho J., et al. ²¹⁾	2008	최적 공기분배시스템 선정을 위한 객관적 방안 연구
Cho J., et al. ²²⁾	2008	최적 냉각시스템 선정을 위한 객관적 방안 연구
Park B., et al. ²³⁾	2013	가변풍량시스템의 냉각시스템을 구성하여 팬 속도 제어를 통한 에너지 절감
Ham S., et al. ²⁴⁾	2014	CRAH의 팬 제어를 통한 데이터센터 실내 환경 모니터링
Kim J. ²⁵⁾	2015	직접 외기도입 및 간접 외기도입 시스템에 대한 최적 운영방안에 관한 연구
Oh B., et al. ²⁶⁾	2017	다양한 차폐방식에 따른 실내 환경 분석 및 최적 공기분배시스템 제안
Cho J., et al. ²⁷⁾	2019	룸 단위와 구역 단위의 공조 및 냉각 방식의 운영효율 비교 분석 및 개선효과 제시

20) 조진균, 홍민호, 성노천, 정차수, 김병선. (2006). 데이터센터의 합리적인 환경제어를 위한 부하패턴 분석 및 에너지소비량 산정에 관한 연구. 대한설비공학회 학술발표대회논문집, 458-463.

21) 조진균, 차지형, 홍민호, 연창근. (2008). 데이터센터의 합리적인 환경제어를 위한 공기 분배 시스템에 대한 연구. 대한설비공학회 학술발표대회논문집, 487-492.

22) 조진균, 정차수, 김병선. (2008). 최적 IT환경제어를 위한 데이터센터의 냉각(열원)시스템 산정에 관한 연구. 대한건축학회 논문집, 계획계, 24(12), 313-320.

23) 박병윤, 정용호. (2013). 가변풍량제어시스템과 냉복도밀폐시스템의 적용에 의한 데이터센터의 냉방에너지 절감 효과 분석. 한국건축환경설비학회 논문집, 7(3), 185-192.

24) 함상우, 김민휘, 윤동섭, 정재원. (2014). 컨테이너먼트가 적용된 모듈러 데이터센터의 공조 팬 제어 방안에 관한 실험적 연구. 대한건축학회 학술발표대회 논문집, 34(2), 285-286.

Table 7. 국외 데이터센터 공조제어시스템 및 제어법 선행연구

저 자	연 도	내 용
Chen J., et al. ²⁸⁾	2012	사이버-물리 시스템의 연동을 위하여 선형 예측모델 개발을 통한 온도 예측
Song Z., et al. ²⁹⁾	2013	데이터센터 실시간 평가를 위한 열환경 예측 모델 개발 및 최적 작동 조건 도출
Song Z., et al. ³⁰⁾	2014	에너지 최적 운영을 위하여 제어 및 최적화를 위한 실시간 환경 예측 ANN모델 개발
Chen J., et al. ³¹⁾	2014	최적 설정온도, CRAC 토출 온도, 내부 팬속도를 포함한 열환경 예측 모델 및 에너지 컨트롤 시스템 개발
Estebe B., et al. ³²⁾	2014	습식 냉각탑 시스템을 사용하는 데이터센터의 최적 설정온도 도출방안에 대한 연구
Gao J. ³³⁾	2014	19가지 환경 변수 및 IT 장비 관련 데이터를 이용한 PUE 인공신경망 예측 모델 개발
Ogawa M., et al. ³⁴⁾	2015	외기 도입 시스템을 적용한 모듈형 데이터센터에서의 MPC 기반 냉각제어 방법 제안
Liu Q., et al. ³⁵⁾	2016	클라우드 매니지먼트 기술을 활용한 데이터센터 공조제어 시스템 개발
Song M., et al. ³⁶⁾	2017	열환경 예측모델 구성 및 CRAC 팬 속도 제어를 통한 에너지 최적 방안 도출
Lazic N., et al. ³⁷⁾	2018	강화학습을 통한 적응형 제어알고리즘 개발

25) 김제영. (2015). 데이터센터의 냉방에너지 사용량 감축을 위한 에너지 절약형 공조시스템 개발. 홍익대학교 석사학위논문.

26) 오보영, 김영일, 김선혜. (2017). 데이터센터의 CFD 해석을 통한 공기분배방식별 공조시스템 비교 연구. 대한설비공학회 학술발표대회논문집, 164-167.

27) 조진균, 박병용, 정용대, 김영팔, 우제상. (2019). 데이터센터 공조·냉각시스템 효율개선을 위한 실험적 연구 :룸 단위에서 구역 단위 공조·냉각방식 변경을 중심으로. 대한설비공학회 논문집, Vol.31, 32-44.

28) Chen, J., Tan, R., Wang, Y., Xing, G., Wang, X., Punch, B., & Colbry, D. (2012). A High_fidelity Temperature Distribution Forecasting System for Data Centers. IEEE 33rd Real-Time Systems Symposium.

데이터센터의 최적 운영 및 통합 에너지 관리 시스템은 IT 전문 기업체에서 솔루션으로 제공하고 있다. 대표적인 기업으로는 미국의 Vigilent, 스위스의 ABB, 일본의 Fujitsu, 한국의 Onionsoftware, 프랑스의 Schneider Electric 등이 있다.

Vigilent는 효율적인 시설 운영을 가능하게 해주는 모니터링, Dynamic Control, 분석, 알람 기능을 통합한 Dynamic Cooling Management System을 제공한다. Dynamic Control은 모니터링 시스템에서 취득한 온도 데이터를 통해 머신러닝을 수행하여 설비의 최적 냉방 상태를 자동으로 결정한다. 각 요소들은 복합적으로 작동되며 자동화된 모니터링 및 설비 제어를 통해 냉방 에너지 비용과 탄소 배출을 감소시킨다³⁸⁾.

-
- 29) Song, Z., Murray, B. T., & Sammakia, B. (2013). Airflow and temperature distribution optimization in data centers using artificial neural networks. *International Journal of Heat and Mass Transfer*, Vol. 64, 80-90.
 - 30) Song, Z., Murray, B. T., & Sammakia, B. (2014). A dynamic compact thermal model for data center analysis and control using the zonal method and artificial neural networks. *Applied Thermal Engineering*, Vol. 62, 48-57.
 - 31) Chen, J., Tan, Rui., Xing, G., & Wang, X. (2014). PTEC: A System for Predictive Thermal and Energy Control in Data Centers. *IEEE Real-Time Systems Symposium*.
 - 32) Estebe, B., LeBot, C., Mancos, J. N., & Arquies, E. (2014). Simulation of a temperature adaptive control strategy for an IWSE economizer in a data center. *Applied Energy*, Vol. 124, 45-56.
 - 33) Gao, J. (2014). *Machine Learning Applications for Data Center Optimization*. Google.
 - 34) Ogawa, M. (2015). Cooling Control of Modular Data Center Utilizing Fresh Air in Consideration ICT Equipment Temperature Management and Energy Saving Based on Model Predictive Control. *Transactions of the Society of Instrument and Control Engineers*, Vol. 51, 561-569.
 - 35) Liu, Q., Ma, Y., Alhussein, M., Peng, L., & Zhang, Yin. (2016). Green data center with IoT sensing and cloud-assisted smart temperature control system. *Computer networks*, Vol. 101, 104-112.
 - 36) Song, M., Chen, K., & Wang, J. (2017). Numerical Study on the Optimized Control of CRACs in a Data Center Based on a Fast Temperature-Predicting Model. *Journal of Energy Engineering*, Vol. 143.
 - 37) Lazic, N., Lu, T., Boutilier, C., & Moonkyung, R. (2018). Data center cooling using model-predictive control. *Proceedings of the Thirty-second Conference on Neural Information Processing Systems*, 3818-3827.
 - 38) Vigilent. (2019. 11). *Dynamic Cooling Management System User Guide for Optimizing Mission Critical Cooling*, Version 6.5.1. <http://www.gcss.online/images/products/vigi/Dynamic%20Cooling%20Management.pdf>

ABB는 통합 관리 시스템으로써 ABB Ability 데이터센터 자동화 시스템을 제공한다. IT, 전력, 냉각 및 빌딩 시스템의 데이터를 통합하여 시설의 거시적, 미시적인 측면에서 관리를 용이하게 하며 지속적인 자동 최적화를 실행한다³⁹⁾.

Fujitsu는 Data Center Management and Automation을 통해 모니터링 프로세스를 통합 및 중앙 집중하고 전체 IT 인프라에 대한 광범위한 보기를 제공한다. 자동으로 문제를 식별하고 시설에 미치는 잠재적 효과에 따라 문제를 분류한 후 우선 순위를 지정하여 규칙 기반 오류 수정 프로세스를 작동한다⁴⁰⁾.

Onionsoftware는 국내 기업으로써 전산실의 온도를 파악하여 데이터센터 CRAC 및 CRAH의 팬 속도 제어를 통한 전력, 냉방 통합관리 시스템을 제공한다⁴¹⁾.

Schneider Electric은 클라우드 시스템 기반의 EcoStruxure Machine Expert를 제공하며 M171, M172 로직 제어기를 통한 에너지 효율 알고리즘을 제공한다. 빌딩 자동화 시스템(Building Management System, BMS)과의 연계가 가능하며 사용자의 요구에 따라 알고리즘의 변형이 가능하다.⁴²⁾

39) ABB. (2019. 11). ABB Ability Data Center Automation. https://library.e.abb.com/public/c968b45403cb4495a574388933f0ece8/Data%20Center%20Automation_A4_v1.pdf.

40) Fujitsu. (2019. 11). Data Center Management and Automation Strategic Briefing. <https://sp.ts.fujitsu.com/dmsp/Publications/public/sb-DCMA-en.pdf>.

41) Onionsoftware. (2019. 11). Key Features of The MK119, Unified BMS+DCIM. <http://www.onionsoftware.com/mk119-dcim.html>.

42) Schneider Electric. (2019. 11). Data Center Management. <https://www.se.com/ww/en/work/solutions/for-business/data-centers-and-networks/cloud-based-dcim-software-dmaas/>

2.3 소결

본 장에서는 연구 목적 설정을 위하여 데이터센터의 기초 개념, 공조제어시스템 적용 현황, 관련 연구 및 최신 기술에 대한 이론 고찰을 실시하였다. 국내의 경우 2010년 이후로 컨테이너 시스템과 외기냉방 시스템을 적극적으로 도입하고 있었으며 대규모 데이터센터의 증가에 따라 중앙 냉수식 시스템을 채택하고 있었다. 반면 국외 선진 데이터센터는 한랭기후에 건설을 하여 항시 외기냉방 운영을 실시하고 있었으며 냉방 시스템은 비상시에 가동하고 있는 것으로 조사되었다. 데이터센터 평균 PUE는 국내가 2.66, 국외가 1.7로 국내 데이터센터의 에너지 효율이 국외에 비해 저조하였으며 이는 기후적 요건에 따른 냉방 시스템 운영 방식에 따른 차이에 기인한 것으로 판단된다. 외기냉방을 실시하기 위해서는 실외 온도가 데이터센터 실내 온도보다 낮아야 하지만 국내의 경우 기후적 특성상 항시 운영이 불가능함에 따라 국내 실정에 맞는 냉방 시스템 운영 및 관리 방안이 필요하다.

데이터센터 공조제어시스템 관련 연구 조사결과 국내의 경우 실내 열환경 모니터링, 설비 종류에 따른 에너지 효율 분석, 최적 공조시스템 제안 등 측정과 분석에 대한 연구가 주를 이루고 있었으며 새로운 제어시스템 및 에너지 운영 방안에 대한 연구는 진행되지 않고 있었다. 하지만 국외의 경우 기계설비적 측면 외에 추가적인 PUE 절감 방법으로써 제어방법 및 최적 알고리즘을 제시하고 있다. 제어방법은 MPC 기반의 열환경 예측이 주를 이루고 있었으며 데이터센터 통합 에너지 운영 및 관리에 대한 연구가 함께 진행되고 있었다. 또한 인공지능망, 강화학습 등의 최신 기술을 적용한 최적 열환경 제공을 위한 연구가 활발히 진행되고 있었다.

따라서 국내 데이터센터 또한 추가적인 에너지 절감 방안으로써 소프트웨어적인 접근이 필요하며, 기존 수동제어 방법에서 야기되는 에너지의 비효율적 운영 및 리모델링이 어렵다는 단점을 고려하여 기존 시스템에 적용이 가능한 최적 제어알고리즘이 필요한 것으로 판단된다. 또한 경제성 및 적용의 용이성을 위하여 각기 다른 데이터센터 환경에서도 스스로 최적화가 가능한 적응형 제어알고리즘의 개발이 필요한 것으로 사료된다.

제 3 장 데이터센터 CFD 모델링

3.1 개 요

데이터센터는 랙의 배치 및 관련 장비 구성 방법에 따라 전산실 개방형, 컨테인먼트, 모듈형으로 분류된다. 이중 컨테인먼트는 최근 신설 데이터센터 및 리모델링을 진행하는 데이터센터에서 적용비율이 증가하고 있는 추세이며 대규모 데이터센터의 증가에 따라 대부분 중앙 냉수식 시스템을 채택하고 있다. 따라서 본 연구에서는 컨테인먼트 데이터센터와 중앙 냉수식 시스템을 모델링 대상으로 선정하였다.

컨테인먼트형 데이터센터는 전산실의 공기와 컨테인먼트 내부의 공기가 혼합되지 않도록 냉복도와 열복도가 모두 차폐된 형태이다. 내부 공기는 CRAC의 냉매 유량 조절에 의하여 온도 제어가 이루어진다. 컨테인먼트 데이터센터 모델링에서 가장 중요한 점은 IT 장비의 발열과 발열량에 따른 풍속 혹은 풍량의 변화이다. 서버의 CPU는 IT 부하에 따라 발열량이 증가하고 발열량에 따라 팬 속도가 저속에서 고속으로 변경된다. 본 모델링 또한 발열량 변화에 의하여 풍량이 자동으로 조절되도록 설정하였으며 조절된 풍량으로 인해 열복도의 온도가 일반 데이터센터의 열복도 온도 범위 안에 들어가도록 풍량 값을 입력하였다.

컨테인먼트 데이터센터는 시스템A, 시스템B의 총 2가지 종류로 모델링을 실시하였다. 시스템A는 데이터센터의 환경 변수를 취득하여 ‘제 4 장’에서 개발될 예측 모델의 학습데이터를 구성하는데 사용된다. 적응형 제어알고리즘은 새로운 데이터센터 환경에서의 적응성 평가가 필요하다. 따라서 시스템B는 시스템A와는 다른 환경의 컨테인먼트로써 성능평가용으로 구성된다. 두 모델의 타당성은 온도 분석 및 기류 분석을 통하여 실시하였다.

3.2 시스템 구성

데이터센터 내부에는 IT 장비를 배치하기 위한 서버실이 존재하며 서버실 내부에는 랙과 CRAC이 배치된다. 랙은 컨테인먼트 시스템에 의해 냉복도와 열복도가 차폐되며 전산실 내부의 공기와 컨테인먼트 내부의 공기는 혼합되지 않는다. 일반적으로 전산실 내부의 공기는 연중 일정하게 유지되도록 별도의 공조가 실시되므로 온도 및 습도 측면에서 컨테인먼트 내부는 외기의 영향이 없는 것으로 가정한다.

공조제어시스템은 중앙 냉수식 시스템이다. 냉각 시스템은 냉각탑, 냉동기, 냉매 분배기, CRAC으로 구성된다. CRAC은 수냉식 시스템으로 증발기 부분에 해당되며 컨테인먼트 내부의 순환공기와 냉매 분배기에서 분배되는 냉매가 열교환을 일으킨다. 냉매 분배기에는 2대의 CRAC이 연결되어 있다. 전산실의 열을 흡수한 냉매는 냉동기로 이동하여 냉수에 열을 전달하며 이는 냉각탑으로 이동해 외부로 열을 방출한다.

냉매 분배기는 냉매 펌프가 포함되어 냉매를 CRAC으로 전달하는 역할을 한다. 냉매는 R134a를 사용하며 20℃의 일정한 온도로 공급되어 상변화에 의한 열교환만 일어나는 것으로 가정한다. 따라서 냉매 유량의 조절을 통해 온도 제어를 실시한다.

본 연구에서는 냉매 유량 조절을 통한 최적 실내 열환경 제공을 목표로 하므로 <그림 4>와 같이 컨테인먼트와 냉매 분배기를 모델링 범위로 설정한다. 컨테인먼트는 전산유체역학(Computational Fluid Dynamics, CFD) 프로그램으로 구축하며 CRAC에서 공기 측의 열량은 (식 2), 냉매 측의 열량은 (식 3)으로 정의한다.




Fig. 4 냉각 시스템 모델링 범위

$$Q_{air} = m_{air}c(T_{RA} - T_{SA}) \quad \dots\dots\dots (\text{식 } 2)$$

여기서,

Q_{air} : 회수 공기와 토출 공기의 열량 차이 [kcal/hr]

m_{air} : CRAC 회수 공기 풍량 [kg/hr]

c : 공기 비열 [kcal/kg℃]

T_{RA} : CRAC 회수 공기 온도 [℃]

T_{SA} : CRAC 토출 공기 온도 [℃]

$$Q_{ref} = m_{ref}(h_{gas} - h_{liquid}) \quad \dots\dots\dots (\text{식 } 3)$$

여기서,

Q_{ref} : 냉매 상태변화시의 현열 흡수량 [kcal/hr]

m_{ref} : 냉매 유량 [kg/hr]

h_{gas} : 기체 상태 냉매 엔탈피 [kcal/kg]

h_{liquid} : 액체 상태 냉매 엔탈피 [kcal/kg]

3.3 CFD 모델링

3.3.1 실시간 분석을 위한 통합 환경 구축

본 연구에서는 실시간 데이터 처리 및 컨테이너먼트 데이터센터 모델과 적응형 예측 제어알고리즘의 연계를 위하여 CFD 프로그램과 컴퓨터 프로그래밍 언어의 통합 환경을 구축하였다. CFD 프로그램으로는 ANSYS의 FLUENT를 채택하였다. FLUENT는 플로우, 난류, 열전달과 산업용 반응 모델링 등 폭 넓은 모델링 환경을 제공하며 확장성이 뛰어나 여러 분야에서 시스템의 환경 및 상황 분석을 위해 사용되고 있다⁴³⁾. 컴퓨터 프로그래밍 언어는 Python을 사용하였다. Python은 1990년 암스테르담의 귀도 반 로섬(Guido Van Rossum)이 개발한 인터프리터 언어다. 데이터 분석, 인공지능 등에 강점이 있고 관련된 다양한 라이브러리를 제공하며 공동 작업 및 유지 보수가 매우 용이하다⁴⁴⁾.

FLUENT는 텍스트 기반의 모델링이 가능하도록 프로그램 내부에 콘솔창(Console)을 제공하며 이를 통하여 경계조건(Boundary Condition)

43) ANSYS. (2019. 11). ANSYS Fluent. <https://www.ansys.com/ko-kr/products/fluids/ansys-fluent>.

44) 박응용. (2019. 11). 점프 투 파이썬. <https://wikidocs.net/4307>.

및 시뮬레이션 조건을 설정할 수 있다. 또한 MATLAB, Python과 연계하여 사용할 수 있는 연동 코드를 제공하여 모델링 및 시뮬레이션 환경을 해당 컴퓨터 프로그래밍 언어의 실행 창에서 제어할 수 있다.

본 연구에서는 ANSYS에서 제공하는 3D 모델링 프로그램인 SpaceClaim을 사용하여 데이터센터의 형상을 모델링 하였으며 메쉬(Mesh) 생성 이후 FLUENT의 경계조건 및 시뮬레이션 조건 설정 단계에서 Python과의 연계를 통해 각종 파라미터(Parameter)를 입력하였다. 시뮬레이션 이후 FLUENT에서 획득한 환경 변수 데이터는 Python으로 전송하여 전처리를 실행하였다.

3.3.2 대상 모델링 계획

모델링 대상은 컨테이너형 데이터센터이며 시스템A와 시스템B 두 가지의 모델링 구축을 목표로 한다. 두 모델은 공통적으로 냉복도 열복도 차폐형이며 랙의 개수와 이에 따른 컨테이너 스케일로 변화를 주었다. 랙에는 10개의 서버가 장착되며 시스템A는 랙 4개와 CRAC 2개, 시스템B는 랙 2개와 CRAC 2개로 구성된다.

CRAC은 냉복도로 찬 공기를 토출하며 토출된 공기는 각 서버에 인입된다. 서버에 인입된 공기는 발열체를 거쳐 열복도로 토출되며 이는 다시 CRAC으로 인입되도록 설정하였다. 구성 및 계획은 <그림 5,6>과 같다.




Fig. 5 시스템A 구성도




Fig. 6 시스템B 구성도

3.3.3 경계조건 설정

두 모델의 공통사항으로는 냉복도와 열복도의 차폐, 랙의 후면인 열복도 공유, 지배 방정식(The Energy Equation)과 난류모델(Turbulence Model), 그리고 환경 변수 입력 조건이 있다. 내부 발열은 서버 발열만 존재하며 외부와의 열교환은 없는 것으로 가정하였다. 유체는 이상기체이며 부력이 작용하는 것으로 설정하였다. 상세 환경 변수 입력 조건 산출 방법은 다음과 같으며 <표 8>과 같이 정리된다.

(1) 서버 발열량

서버 발열은 IT 부하에 의해 결정된다. 일반적으로 랙은 평시에 4 kW/rack, IT 부하가 높을 때 6.6 kW/rack의 발열량이 발생한다. 시스템A와 모델B는 랙 당 10개의 서버가 장착되었다. 따라서 서버 당 발열량은 평시에 400 W/server, 발열 시 660 W/server로 가정한다. 해당 모델에서 서버 내부 유로의 면적은 0.24m^2 이므로 평시에는 $1,666.67\text{ W/m}^2$, 발열 시에는 $2,750\text{ W/m}^2$ 으로 입력하였다.

(2) 서버 풍량

서버에는 CPU가 장착되어 있으며 IT 부하로 인해 발열이 증가한다. 발열에 따라 서버 내부 팬의 가동 속도가 저속에서 고속으로 바뀌며 이때 더 많은 풍량이 유입되어 서버를 냉각시킨다. 일반적인 데이터센터는 각 서버의 IT 부하가 시간에 따라 불규칙하기 때문에 냉복도와 열복도의 차압을 측정하여 풍량을 제어한다. 하지만 본 연구에서는 시뮬레이션의 편의를 위하여 필요 풍량을 산출하여 대입하였다. 풍량 산출에는 열전달 관계를 설명하는 (식 4)가 사용되었다.

$$Q_{server} = m_{air} c \Delta T \quad \dots\dots\dots (\text{식 } 4)$$

여기서,

Q_{server} : 서버의 발열량 [kcal/hr]

m_{air} : 서버의 풍량 [kg/hr]

c : 공기 비열 [kcal/kg℃]

ΔT : 냉복도와 열복도의 온도차 [℃]

서버의 발열량이 400 W 일 때, 1 kW는 약 860 kcal/hr 이므로 Q_{server} 는 344 kcal/hr이다. 공기 비열은 0.24 kcal/kg℃로 고정 상수이다. 일반적인 데이터센터 냉복도와 열복도의 온도차는 선행연구에 따라 10~12℃로 가정하며⁴⁵⁾ $\Delta T = 11℃$ 로 대입한다. 이때 서버 풍량 m_{air} 는 400 W의 서버 발열을 ΔT 가 11℃가 되도록 하는 풍량이며 $m_{air} = 130.30$ kg/hr이다. FLUENT의 풍량 입력 단위는 kg/sec이므로 $m_{air} = 0.0361$ kg/sec로 변환되어 입력된다. 마찬가지로 서버의 발열량이 660 W일 때 서버 풍량은 0.0597 kg/sec이다. 즉, 서버의 발열량이 400 W에서 660 W로 변환될 때 서버 풍량 또한 0.0361 kg/sec에서 0.0597 kg/sec로 변경된다.

(3) CRAC 토출 풍량

본 모델에서는 냉복도와 열복도가 모두 차폐되어 있으므로 외부 공기의 출입이 없다. 따라서 CRAC의 토출 풍량은 랙 후면에서 토출되는 풍량의

45) 조진균, op. cit., p.104.

총합과 같다. 초기 설정 시 서버가 모두 저속으로 구동된다는 가정 하에 0.361 kg/sec의 값이 입력된다. 이후에는 Time Step 마다 CRAC에 인입되는 풍량 값이 입력된다.



Table 8. 시스템A, B의 경계조건 입력

구 분		특 징
Server	Heat Value	1,666.67 W/m ² (Low IT Load) 2,750 W/m ² (High IT Load)
	Mass Flow Rate	0.0361 kg/sec (Low IT Load) 0.0597 kg/sec (High IT Load)
CRAC	Initial Supply Air Temperature	24℃
	Initial Supply Air Flow Rate	0.361 kg/sec

3.3.4 CFD 모델링 분석

CFD 모델링 타당성 확인을 위하여 두 모델에 대한 저발열인 경우와 고발열인 경우의 온도 및 기류 흐름 분석을 실시하였다. <표 9>는 환경 변수 분석 위치를 나타낸다. 온도 분석은 서버 유로를 확인할 수 있는 단면 위치인 $x = 0.3\text{m}$ 지점에서 실시하였으며 기류 흐름은 전체 조감도를 통해 파악하였다.

Table 9. 시스템A, B의 온도 분석 위치

	시스템A	시스템B
온도		

시스템A의 온도 분포도는 <표 10>과 같다. 저발열의 경우 모든 서버에 대해 발열량 $1,666.67 \text{ W/m}^2$, 풍량 0.0361 kg/sec 가 입력되었으며 고발열은 모든 서버에 대해 발열량 $2,750 \text{ W/m}^2$, 풍량 0.0597 kg/sec 가 입력되었다. 온도는 냉복도의 중간지점, 열복도의 중간지점에서 측정하였다. 저발열의 냉복도 온도는 24°C , 열복도 온도는 34.85°C 로 측정되었으며 고발열의 냉복도 온도는 24°C , 열복도 온도는 35.2°C 로 측정되었다.

시스템B 또한 시스템A와 같은 조건으로 시뮬레이션을 실행하였으며 온도 분포도는 <표 11>과 같다. 저발열의 냉복도 온도는 24°C , 열복도 온도는 34.97°C 이며 고발열의 냉복도 온도는 24°C , 열복도 온도는 35.32°C 로 측정되었다.

따라서 시스템A와 시스템B의 냉복도와 열복도의 온도 차이는 일반 데이터센터 냉복도와 열복도의 온도 차이인 $10\sim 12^\circ\text{C}$ 범위를 만족시켰으며, 풍량과 발열량의 관계가 잘 확립된 것으로 사료된다.

기류 분포도는 기류 흐름선으로 표현하였으며 <표 12>와 같다. 시스템A와 시스템B 모두 CRAC에서 유체가 토출되어 서버 유로를 지나 CRAC 인입부로 회수되는 모습을 나타냈다. 또한 CRAC 토출 풍속이

일반적인 데이터센터 토출 풍속인 1.0~2.5m/s 범위⁴⁶⁾를 만족시켜 유체의 입력과 출력의 관계 및 풍량과 풍속의 관계가 명확하게 정의된 것으로 분석된다.

46) 조진균, op. cit., p.82.

Table 10. 시스템A 온도분포도



	시스템A
저발열	
온도	냉복도 : 24℃, 열복도 : 34.85℃
고발열	
온도	냉복도 : 24℃, 열복도 : 35.21℃

Table 11. 시스템B 온도분포도




	시스템B
저발열	
온도	냉복도 : 24℃, 열복도 : 34.97℃
고발열	
온도	냉복도 : 24℃, 열복도 : 35.32℃

Table 12. 시스템A & 시스템B 기류 흐름도



3.4 소 결

본 장에서는 환경 변수 데이터 취득과 적응형 예측 제어알고리즘의 평가를 위한 컨테이너먼트 데이터센터 시스템A와 시스템B의 CFD 모델링을 실시하고 타당성을 분석하였다. 상세 과정 및 결과는 다음과 같다.

(1) 실시간 분석을 위한 통합 환경 구축

본 연구에서 모델링은 ANSYS의 Fluent CFD 프로그램, 예측모델 및 제어알고리즘 개발에는 컴퓨터 프로그래밍 언어인 Python을 사용하였다. 데이터센터 모델에 개발 로직을 적용하기 위해서는 두 프로그램간의 실시간 상호 피드백 과정이 필요하다. 따라서 ANSYS에서 제공하는 연결 코드를 사용하여 두 프로그램의 호환 체계를 구축하였다.

(2) CFD 모델링

시스템A와 시스템B는 환경 조건 및 경계 조건을 동일하게 적용하나 랙의 수를 변경시켜 구조상의 차이를 부여하였다. 두 시스템 모두 냉복도와 열복도 차폐형으로 외부와의 침기 및 열교환은 이루어지지 않는 것으로 가정했으며 일반 데이터센터 열환경을 모사하기 위하여 (식 4)를 이용하여 풍량을 산출하였다. 이에 따라 경계 조건은 저발열 시 서버 발열 1666.67 kg/hr, 서버 풍량 0.0361 kg/sec을 입력하였고 고발열 시 서버 발열 2,750 kg/hr, 서버 풍량은 0.0597 kg/sec로 설정하였다. 또한 서버의 발열이 저발열에서 고발열로 변경되면 서버 풍량은 자동으로 증가하도록 설정하였으며, CRAC 토출 공기의 풍량은 CRAC으로 회수되는 풍량의 총합으로 토출되도록 설정하였다.

(3) 모델링 타당성 분석

모델링 타당성 분석은 냉복도와 열복도의 온도 분포 및 전체적인 기류 흐름에 대하여 실제 데이터센터 실내 환경과의 유사정도를 판단함으로써 시행하였다. 시뮬레이션은 두 시스템 각각의 모든 서버가 저발열인 경우와 고발열인 경우로 나누어 실행하였다. 그 결과 시스템A는 저발열인 경우 냉복도가 24℃ 일 때 열복도가 34.85℃, 고발열인 경우 냉복도가 24℃ 일 때 열복도가 35.21℃로 측정되었다. 시스템B는 저발열에서 냉복도가 24℃, 열복도가 34.97℃ 였으며 고발열의 경우에는 냉복도가 24℃ 일 때 열복도가 35.32℃로 측정되었다. 두 시스템 모두 실제 데이터센터 냉복도와 열복도의 온도차이인 10~12℃ 범위 안에서 온도 분포가 이루어졌으며 기류 흐름 또한 CRAC에서 토출되어 서버 유로를 지나 열복도로 토출되는 모습을 나타냈다. 따라서 시스템A와 시스템B는 실제 데이터센터의 실내 환경을 잘 모사한 것으로 판단된다.

제 4 장 적응형 제어알고리즘 개발

4.1 개 요

기존 실내 환경 제어 방법으로는 대표적으로 ON&OFF 시스템, PID 시스템이 있다. 두 시스템 모두 자동제어로 사용될 수 있으나 ON&OFF 시스템의 경우 잦은 절전으로 인하여 시스템에 무리가 가고 CRAC 급기온도를 설정온도에 정확하게 맞출 수 없다는 단점이 있다. 또한 PID 시스템은 CRAC 급기온도가 설정온도에 맞춰가도록 튜닝이 가능하나 튜닝이 적용된 시스템에만 최적 결과물을 제공할 수 있다는 단점이 있어 새로운 환경에서는 관리자의 경험에 의존하여 수동적으로 튜닝을 실시하여야 한다. IT 장비는 온도가 일정치 이상으로 상승하면 가동을 멈추는 문제가 발생하기 때문에 허용 범위 이상의 온도 상승을 방지해야 한다. 이러한 요인들로 인해 많은 데이터센터에서는 권장온도보다 낮은 온도로 실내 환경을 유지하고 있으며 이는 불필요한 에너지 소비를 야기시킨다. 따라서 기존 시스템들의 단점들을 보완하기 위하여 본 연구에서는 인공지능 기반의 냉매 유량 예측모델과 자가 학습이 가능한 적응형 제어알고리즘을 개발하였다.

인공신경망(Artificial Neural Network, ANN)은 1943년 Warren McCulloch와 Walter Pitts에 의해 처음 제시된 개념으로써 인간 뇌의 신경망을 모사한 시스템이다⁴⁷⁾. 1957년 코넬 항공 연구소(Cornell Aeronautical Lab)의 Frank Rosenblatt는 가장 간단한 인공신경망 모델인 퍼셉트론(Perceptron)을 고안하였다⁴⁸⁾. 퍼셉트론은 각 노드(Node)에서

47) McCulloch, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. The bulletin of mathematical biophysics, 5(4), 115-113.

48) Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model for Information

입력 값과 가중치(Weight)를 곱해 모두 합한 값이 활성화 함수(Activation Function)에 의해 판단되어 이 값이 임계치보다 높으면 값을 출력하는 방식으로 작동한다. 노드(Node)는 뉴런(Neuron)으로도 불리며 신경망의 기초를 이룬다. 신경망은 입력 노드로 구성된 입력층(Input Layer), 가중치를 주며 입력된 신호를 전달하는 은닉층(Hidden Layer), 은닉층으로부터 전달 받은 신호를 출력하는 출력층(Output Layer)으로 구성되어 있다. 이때 입력층의 뉴런은 가중치를 가지지 않으며 은닉층과 출력층의 뉴런은 퍼셉트론 알고리즘을 사용한다. 학습은 신경망의 순전파(Feed-Forward)를 통해 출력된 값을 정답과 비교하고 역전파(Back-Propagation) 알고리즘을 통해 오차를 최소화하는 방향으로 가중치를 수정하며 학습이 이루어진다. 인공신경망의 구조 및 학습과정은 <그림 7>과 같다.




Fig. 7 인공신경망의 개념 및 구조

Storage and Organization in the Brain. Cornell Aeronautical Laboratory, Psychological Review, v65, No. 6, 386-408.

인공신경망은 학습 방법에 따라 지도학습(Supervised Learning), 비지도학습(Unsupervised Learning) 그리고 강화학습(Reinforced Learning)으로 구분된다. 지도학습은 학습 데이터에 입력 값에 대한 정답이 포함되어 있으며 선형 회귀(Linear Regression), 서포트벡터머신(Support Vector Machine), 결정트리(Decision Tree) 등에 주로 사용된다. 비지도학습은 학습 데이터에 정답이 포함되지 않은 형태로 스스로 입력에 대한 규칙을 학습하여 군집화(Clustering), 시각화(Visualization), 차원축소(Dimensionality Reduction) 등을 수행하며 강화학습은 과거의 결과가 충분하지 않은 상태에서 의사결정에 의한 결과를 토대로 미래의 가치를 극대화시키는 전략을 스스로 학습하는 방법이다⁴⁹⁾.

딥러닝(Deep Learning)은 인공신경망에서 은닉층의 개수가 2개 이상인 것을 의미하며 다양한 분야에서 활용되고 있다. 대표적으로는 IT, 광고, 자동차, 센서, 데이터 분석 등이 있다. 최근에는 건축 환경 분야에서도 공조시스템, 냉난방제어, 에너지 효율 분석, 열쾌적 등에 대한 연구가 활발히 진행되고 있다. 관련 연구로는 건물에너지 절약을 위한 HVAC 시스템 부하 예측⁵⁰⁾, 에너지 수요 및 공급 예측을 위한 개별 건물의 속성, 시스템 효율, 환경 변수 관계 분석에 대한 연구⁵¹⁾ 등이 있다.

본 연구 또한 최적 실내환경 제공을 위한 냉방시스템 제어가 목적이다. 적용되는 냉방시스템은 R134a 냉매를 20℃로 일정하게 공급하며 밸브의 유량제어를 통해 CRAC의 급기온도를 설정온도에 맞도록 공급한다.

49) Aurelien, G., (2017). Hands-On Machine Learning with Scikit-Learn and TensorFlow. United States of America: O'REILLY, 7-12.

50) Rubio-Herrero, J., Chandan, V., Siegel, C., Vishnu, A., & Vrabie, D. (2017). A Learning Framework for Control-Oriented Modeling of Buildings. 2017 16th IEEE International Conference on Machine Learning and Applications(ICMLA).

51) 강인성. (2017). 오피스건물 공조시스템의 인공신경망 기반 에너지사용량 예측모델 개발. 중앙대학교 석사학위논문, p.13.

하지만 불규칙적으로 변하는 데이터센터의 환경을 수학적으로 모델링하는 것을 매우 어려우며 데이터센터의 형식에 따라 상이하다. 따라서 본 장에서는 인공신경망을 활용하여 최적 냉매 유량 예측모델을 개발하고 이를 적용한 자가 학습 능력을 가진 적응형 제어알고리즘을 개발하였다.

4.2 냉매 유량 예측모델 개발

4.2.1 입력 변수 설정 및 데이터 구축

인공신경망은 선별된 데이터를 통해 학습을 진행하므로 입력되는 데이터의 종류가 매우 중요하다. 입력 데이터의 선별에는 회귀분석(Regression Analysis), 유전자 알고리즘(Genetic Algorithm), 상호 정보량(Mutual Information) 등의 방법이 사용된다⁵²⁾. 각 모델 모두 선정된 데이터의 적합도를 평가하는 지표를 사용하고 있으며 종속변수와 독립변수의 관계가 낮은 데이터는 입력 데이터 상에서 제외시키는 과정을 거친다. 하지만 본 연구에서는 열전달 수식을 사용하여 필요 냉매 유량을 산정하며 입력 데이터는 수식에 필요한 변수로 최소화하여 구성하였다. 산출 과정은 다음과 같다.

$$Q = m_{air} c (T_{RA} - T_{SET}) = m_{ref} (h_{gas} - h_{liquid}) \quad \dots\dots\dots (\text{식 } 5)$$

여기서,

Q : 회수온도가 설정온도로 되기 위해 제거되어야 할 열량 [kcal/hr]

c : 공기 비열 [kcal/kg °C]

52) 강인성. op. cit., p.22.

m_{air} : CRAC 회수 공기 풍량 [kg/hr]

m_{ref} : 열량을 제거하기 위한 요구 냉매 유량 [kg/hr]

T_{RA} : CRAC 회수 공기 온도 [°C]

T_{SET} : 설정온도 [°C]

h_{gas} : 기체 상태 냉매 엔탈피 [kcal/kg]

h_{liquid} : 액체 상태 냉매 엔탈피 [kcal/kg]

본 연구에서는 배관의 면적, 두께, 스케일 등과 상관없이 100% 열교환이 일어나며 R134a 냉매가 20°C의 일정한 온도로 공급되어 상변화에 의한 열교환만 일어난다고 가정한다. 먼저, CRAC의 회수 공기 풍량, 회수 공기 온도, 설정온도, 공기 비열 값을 이용하여 회수되는 공기가 설정온도가 되기 위해 제거되어야 할 열량을 계산한다. 공기 비열은 0.24 kcal/kg°C로 상수이다. 따라서 산출된 열량은 곧 냉매가 제어해야할 열량과 같다. R134a 냉매가 20°C에서 상변화 할 때 엔탈피 차이는 182.28 kJ/kg이며 이는 43.57 kcal/kg과 같다⁵³⁾. 따라서 열량을 냉매의 상변화 엔탈피 값으로 나누어 필요 냉매 유량을 산출한다.


예측모델 개발을 위해 필요한 데이터를 얻기 위하여 시스템A로 시뮬레이션을 진행하였으며 계획은 <표 13>과 같다. 30초 단위로 데이터를 취득하였으며 매 Time Step 마다 10회의 계산을 시행하였다. 온도와 풍량은 CRAC Inlet 1, CRAC Inlet 2, CRAC Outlet 1, CRAC Outlet2의 면 평균(Surface Average)으로 측정하였다. 토출 공기 온도는 CRAC Inlet 1과 CRAC Inlet 2의 평균값, 회수 공기 온도는 CRAC Outlet 1과 CRAC Outlet 2의 평균값을 사용하였으며 회수 공기 풍량은

53) ARKEMA, (2019. 11). Forane 134a, Thermodynamic Properties - SI (2010). <https://www.forane.com/export/shared/.content/media/downloads/products-documentations/fluorochemicals/forane-134a-thermodynamic-properties-si.pdf>.

CRAC Outlet 1과 CRAC Outlet 2의 합으로 산출하였다.

다양한 환경 변수 취득을 위하여 Rack1에서 Rack4까지 번갈아가며 300초 단위로 발열 및 풍량을 변경하였다. 이때 경우의 수는 서버의 발열 및 풍량 변경이 없는 경우부터 모두 변경이 된 경우까지 총 41가지이다. 이 41가지 경우의 수에 대하여 CRAC 토출 온도를 18~27℃ 범위에서 1℃씩 상승시켜 변경하였으며 CRAC 회수 공기 온도는 CRAC 토출 온도에 따라 변화한다. 또한 모든 경우에 대하여 18~27℃ 범위의 설정온도를 부여하여 총 41,000가지의 데이터를 구성하였다.

Table 13. 시스템A 시뮬레이션 계획

시스템A 데이터 측정 위치		
		
구 분	내 용	
Time Step	30sec	
Iteration	10	
Simulation Cycle	1cycle = 300sec	
Simulation Cycle (n=1...10)	1n	Rack 1 Heat & Flow Rate Increases
	2n	Rack 2 Heat & Flow Rate Increases
	3n	Rack 3 Heat & Flow Rate Increases
	4n	Rack 4 Heat & Flow Rate Increases
Heat Increase	$1,666.67\text{W/m}^2 \rightarrow 2,750\text{W/m}^2$	
Mass Flow Rate Increase	$0.0361\text{kg/sec} \rightarrow 0.0597\text{kg/sec}$	
Data Export	CRAC Inlet 1 Average Temperature CRAC Inlet 2 Average Temperature CRAC Outlet 1 Average Temperature CRAC Outlet 2 Average Temperature CRAC Inlet 1 Average Mass Flow Rate CRAC Inlet 2 Average Mass Flow Rate CRAC Outlet 1 Average Mass Flow Rate CRAC Outlet 2 Average Mass Flow Rate	

시스템A 시뮬레이션을 통해 획득한 환경 변수 데이터는 (식 5)에 의해 냉매 유량을 산출하는데 사용된다. 계산의 용이성을 위하여 온도 단위는 $^{\circ}\text{C}$, 풍량 단위는 kg/hr 로 통일하였다. 시뮬레이션을 통해 얻은 데이터는 입력데이터(Input Data)로, 산출 된 필요 냉매 유량은 출력데이터(Output Data)로 구성된다. 데이터세트 형식은 <그림 8>과 같다.




Fig. 8 최종 데이터세트 구성

구성된 데이터세트를 인공신경망 학습에 바로 사용하면 과적합(Overfitting)이 될 가능성이 있다. 따라서 데이터가 인공신경망에 학습되기 이전에 과적합을 방지해주고 학습속도를 증가시키는 전처리의 과정이 필요하다. 데이터 전처리에는 주로 정규화(Normalization)와 표준화(Standardization)가 사용된다. 정규화는 데이터의 구간을 0~1 사이로 조정하며 표준화는 데이터를 평균 0, 표준편차 1의 데이터 분포로 재생성한다⁵⁴⁾. 이를 수식으로 표현하면 <표 14>와 같다. 본 연구에서 사용되는 데이터는 표준분포를 나타내지 않기 때문에 정규화를 사용한다. 단, 적응형 제어알고리즘에서 새로 유입될 데이터를 고려하여 온도의 최솟값은 0, 최댓값은 100으로 설정하고 유량의 최솟값은 0, 최댓값은 10,000으로 설정하여 최종 데이터세트를 구성하였다.

54) Muller, A., & Guido, S. (2017). Introduction to machine learning with Python. United States of America: O'REILLY, 169-173.

Table 14. 데이터 전처리 기법

구 분	정규화 (Normalization)	표준화 (Standardization)
수 식	$\frac{X_{element} - X_{minimum}}{X_{maximum} - X_{minimum}}$	$\frac{X_{element} - X_{average}}{\sigma_{Standard Deviation}}$

4.2.2 예측모델 개발

예측모델 개발은 Python과 Tensorflow를 통하여 실시하였다. Tensorflow는 구글에서 개발한 오픈소스 라이브러리로 머신러닝 및 딥러닝에 맞추어 다양한 기능을 제공해준다⁵⁵⁾. 본 연구에서의 예측모델은 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 온도, CRAC 회수 공기 풍량을 입력으로 하여 냉매 유량을 출력으로 한다.

(1) 인공신경망 적용 함수

예측모델 개발을 위해서는 손실함수(Loss Function), 뉴런의 활성화 함수(Activation Function), 그리고 최적화 알고리즘(Optimization Algorithm)을 설정해 주어야 한다. 손실함수는 신경망의 학습상태를 측정하는 하나의 지표로써 평균제곱오차(Mean Squared Error, MSE)와 교차 엔트로피 오차 (Cross Entropy Error)가 있다. 평균제곱오차는 (식 6)과 같이 예측값과 실제값의 오차를 제공하여 평균을 구한 것이며 일반적으로 회귀에서 많이 사용된다. 예측모델의 학습은 평균제곱오차를 최소화하는 방향으로 가중치를 수정하여 학습을 진행한다.

55) Aurelien, G. (2017). Hands-On Machine Learning with Scikit-Learn and TensorFlow. United States of America: O'REILLY, 7-12.

$$\frac{1}{N} \sum_i (y_i - \hat{y})^2 \quad \dots\dots\dots \text{(식 6)}$$

여기서,

N : 표본의 개수




y_i : 입력에 대한 실제값

$\hat{y}$: 입력에 대한 예측값

활성화 함수는 뉴런의 입력에 대해 출력을 결정하는 함수이다. 일반적으로 사용되는 활성화 함수는 계단함수(Step Function), 시그모이드 함수(Sigmoid Function), tanh 함수(Hyperbolic Tangent Function), ReLU 함수(Rectified Linear Unit Function)가 있으며 <표 15>와 같다. 계단함수는 입력이 양수일 때는 1을 출력하고 음수일 때는 0을 출력하는 이진적(Binary) 함수이다. 하지만 출력 사이에 값이 없어 미분이 불가능하여 미분을 활용한 최적화 함수에서 쓸 수 없다는 단점이 있다. 시그모이드 함수는 모든 구간에서 미분 값이 존재하며 $x = 0$ 일 때 0.25로 가장 큰 미분 값을 가진다. 딥러닝에서는 은닉층이 많아질수록 곱하기 연산이 중첩되어 기울기 소실(Vanishing Gradient) 문제가 발생한다. tanh 함수는 시그모이드 함수의 단점을 보완하고자 나온 함수이며 입력신호를 -1~1의 값으로 정규화 한다. $x = 0$ 일 때 최대 미분 값은 1이나 마찬가지로 기울기 소실 문제가 발생한다. ReLU 함수는 현재 딥러닝 분야에서 가장 많이 통용되고 있는 활성화 함수이다. 음수 입력은 0으로 처리하고 양수 입력은 선형으로 출력한다. 기울기가 0 혹은 1로 기울기 소실문제가 발생하지 않으며 시그모이드 함수, tanh 함수보다 빠른 학습속도를 나타낸다⁵⁶⁾.

56) 조운환, 서영덕, 박대준, 정제창. (2016). DNN에서 효율적인 학습을 위한 활성화 함수

Table 15. 활성화 함수의 종류

함 수	그래프	수 식
계단함수 (Step Function)		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$
시그모이드 함수 (Sigmoid Function)		$f(x) = \frac{1}{1 + e^{-x}}$
tanh 함수 (Hyperbolic Tangent Function)		$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$
ReLU 함수 (Rectified Loney Unit Funtion)		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$

최적화는 손실함수를 최소화 시키는 파라미터(Parameter)들을 찾는 과정을 의미한다. 최적화 알고리즘은 확률적 경사 하강법(Stochastic Gradient Descent), 모멘텀(Momentum), Adagrad (Adaptive Gradient), RMSProp, Adam (Adaptive Moment Estimation) 등이 있다. Adam 알고리즘은 2015년 제안된 새로운 방법으로 모멘텀과 RMSProp의 장점을 합친 알고리즘이다⁵⁷⁾. 가중치를 수정하는 과정에서 가속도의 개념을 적용하였으며 학습 과정동안 자동으로 학습률(Learning Rate)을 최적화 시켜주기 때문에 초기 학습률을 지정해 주며 일반적으로 0.001의 초기

에 대한 고찰. 대한전자공학회 학술대회, 800-803.

57) Aurélien, G. op. cit., p.383.

학습률을 입력한다⁵⁸⁾. 따라서 예측모델 개발에 사용되는 함수들은 <표 16>과 같다.

Table 16. 인공신경망 적용 함수

구 분	함 수
손실함수 (Loss Function)	평균제곱오차 (Mean Squared Error)
활성화 함수 (Activation Function)	ReLU 함수 (Rectified Linear Unit Function)
최적화 알고리즘 (Optimization Algorithm)	Adam 알고리즘 (Adaptive Moment Estimation Algorithm)

(2) 인공신경망 구조 설정

인공신경망의 초기 구조는 정해진 바가 없다. 따라서 Moon⁵⁹⁾의 선행연구에 기반 하여 입력층, 은닉층, 출력층, 숨겨진 뉴런의 개수를 결정하였다. 입력층, 은닉층, 출력층은 각각 1개이며 입력 뉴런의 개수는 입력 데이터인 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 온도, CRAC 회수 공기 풍량에 따라 4개, 출력 뉴런의 개수는 냉매 유량을 출력하는 뉴런 1개, 은닉층의 숨겨진 뉴런은 (식 7)에 따라 9개로 결정했으며 구조는 <그림 9>와 같다.

$$2N_i + 1 \quad \dots\dots\dots \quad (\text{식 } 7)$$

여기서,

N_i : 입력 뉴런의 개수

58) 최은지. (2019). 딥러닝 기반 재실자 포즈별 MET 산출모델 개발. 중앙대학교 석사학위 논문.
59) Moon, J. W. (2009). ANN-Based Model-Free Thermal Controls for Residential Buildings. Ph.D.diss., University of Michigan.




Fig. 9 초기 인공신경망 구조

학습 데이터는 ‘4.2.1 절’에서 구성된 41,000개의 데이터세트를 사용한다. 개발된 모델의 성능평가를 위해서는 학습 데이터와 테스트 데이터의 분리가 필요하다. 이는 Python 라이브러리인 Sklearn에서 제공하는 Train Test Split 기능을 통해 임의로 데이터를 섞은 후, 9:1의 비율로 데이터 분리를 실시하였다. 데이터세트의 구성은 <그림 10>과 같으며 초기 모델의 최종 요약은 <표 17>과 같다. 개발된 초기 모델은 통계적 기법에 따라 타당성을 검증한 후 최적화를 진행한다. 최적화는 학습률, 은닉층의 수, 숨겨진 뉴런에 대해 시행된다.




Fig. 10 데이터세트의 구성

Table 17. 인공신경망 초기 모델

구 분		내 용
Structure	Input Layer	• Number of Neurons : 4 - Setpoint Temperature - Supply Air Temperature - Return Air Temperature - Return Air Mass Flow Rate
	Hidden Layer	• Number of Neurons : 9 - Using <Equation 1>
	Output Layer	• Number of Neuron : 1 - Refrigerant Mass Flow Rate
Functions	Loss Function	• Mean Squared Error (MSE)
	Activation Function	• ReLu Function (Rectified Linear Unit Function)
	Optimization Algorithm	• Adam Algorithm (Adaptive Moment Estimation Algorithm)
Training Method		• Epoch : 100 times • Learning Rate : 0.001

4.3 적응형 제어알고리즘 개발

4.3.1 보정인자 설정

적응형 제어알고리즘에는 최적화가 완료된 예측모델이 내재된다. 하지만 예측모델은 시스템A의 환경변수로 학습이 진행된 모델이며 환경이 다른 데이터센터에 적용되었을 시 해당 환경에 대한 최적 냉매 유량의 학습이 필요하다. 따라서 적응형 제어알고리즘에는 예측모델의 출력값에 대하여 오차를 보정해주고 보정된 값에 대해 새로운 학습데이터를 생성하여 예측모델을 수정하는 과정이 필요하며 이는 보정인자를 추가함으로써 이루어진다. 새로운 환경에 대한 최적 냉매유량은 (식 8)에 의하여 산출된다.

$$m_{new} = m_{old} + \alpha (T_{SA(n+1)} - T_{SET(n)}) \quad \dots\dots\dots \text{(식 8)}$$

여기서,

m_{new} : 보정된 냉매 유량 [kg/hr]

m_{old} : 예측 냉매 유량 [kg/hr]

α : 보정인자

$T_{SA(n+1)}$: n+1 번째 사이클의 CRAC 토출 공기 온도 [°C]

$T_{SET(n)}$: n 번째 사이클의 설정온도 [°C]

예로써, n 번째 사이클에서 설정온도가 21°C로 입력되었을 때 예측모델에 의해 냉매 유량이 440 kg/hr로 도출되고 이로 인한 n+1 번째 사이클의 CRAC 토출 공기 온도가 23°C라면, 보정된 냉매 유량은 440 +

$\alpha(23 - 21)$ 로 계산된다. 이때 $\alpha = 1.5$ 이면 보정된 냉매 유량은 $440 + 3 = 443 \text{ kg/hr}$ 이며 n 번째 사이클의 환경변수와 함께 데이터세트화 되어 냉매 유량 예측모델에 학습된다. 즉, 예측된 냉매 유량은 (식 8)에 의해 온도의 오차와 보정인자의 곱만큼 보정되며 이로 인해 n 번째 사이클의 환경 변수에 의한 냉매 유량 예측값은 440 kg/hr 가 아닌 443 kg/hr 로 수정된다. 443 kg/hr 의 냉매 유량은 반드시 n 번째 사이클의 상황에 대한 정답은 아니며 α 에 따라 학습되는 냉매 유량 데이터가 달라진다. 따라서 보정인자의 다각화를 통하여 새로운 환경에 대한 최적 보정인자를 찾는 최적화 과정을 거쳐야 한다.

4.3.2 제어알고리즘 구축

제어 알고리즘은 냉매 유량 예측모델과 (식 8)에 의한 보정과정 및 예측모델 재학습의 과정을 포함한다. 재학습 과정을 통하여 예측모델을 새로운 시스템에 적응시키며 최적 열환경 제공을 위하여 이 과정을 계속적으로 반복한다.

제어 알고리즘을 구축하기 이전에 제어 사이클에 대한 이해가 선행되어야 한다. 본 연구에서의 컨테인먼트형 데이터센터는 5분 간격의 제어 사이클을 가지며 매 제어 주기마다 환경 변수를 취득해 다음 제어 사이클을 위한 최적 냉매 유량을 도출하여 적용한다. 이를 도식화 하면 <그림 11>과 같다.




Fig. 11 제어 사이클 개념도

제어 알고리즘은 제어 사이클을 기초로 하여 구성되며 <그림 12>와 같다. 시뮬레이션이 진행되고 있을 때 n 번째 제어 사이클에 도달하면 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 온도, CRAC 회수 공기 풍량 데이터를 추출하여 전처리 과정을 거쳐 예측모델에 입력한다. 예측모델은 입력 값에 해당하는 냉매 유량을 출력하고 5분의 시뮬레이션을 진행한다. $n+1$ 번째 사이클에서 다시 환경 변수를 추출하고 이때 CRAC 토출 공기 온도와 n 번째 사이클의 설정온도를 비교한다. 두 값이 같으면 계속 시뮬레이션을 진행하고 두 값이 다르면 (식 8)을 통해 n 번째 사이클의 최적 냉매 유량을 산출한다. 최적 냉매 유량은 데이터 처리 과정을 거쳐 n 번째 사이클의 환경 변수와 함께 학습 데이터로 구성되어 예측모델에 재학습된다. 이후 수정된 예측모델을 불러와 제어 사이클을 반복 수행한다. 해당 알고리즘을 통해 예측모델은 지속적으로 수정되며 새로운 환경에 적응해간다.




Fig. 12 적응형 제어알고리즘

4.4 소결

본 장에서는 학습 데이터세트 구성 및 냉매 유량 예측모델과 적응형 제어알고리즘을 개발하였다. 학습 데이터세트는 냉매 유량 예측모델의 학습에 사용되며 냉매 유량 예측모델은 적응형 제어알고리즘에 사용된다. 자세한 내용은 다음과 같다.

(1) 입력 변수 설정 및 데이터 취득

냉매 유량 산출을 위한 학습 데이터세트의 구성은 (식 5)에 의해 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 온도, CRAC 회수 공기 풍량, 냉매 유량으로 결정되었다. 환경 변수 데이터는 다양한 상황에 대한 시스템A의 시뮬레이션을 통해 취득하였으며 총 41,000개의 데이터 세트를 구성하였다. 해당 데이터는 전처리 과정을 통해 예측모델의 학습에 사용될 수 있도록 구성되었다.

(2) 예측모델 개발

냉매 유량 예측모델은 컴퓨터 프로그래밍 언어인 Python과 Tensorflow를 이용해 개발되었다. 각종 적용 함수의 비교를 통하여 손실함수는 평균제곱오차, 활성화 함수는 ReLu 함수, 최적화 알고리즘은 Adam 알고리즘이 선정되었다. 인공신경망의 구조는 입력층 1개, 은닉층 1개, 출력층 1개로 구성되었으며 각각 입력 뉴런 4개, 숨겨진 뉴런 9개, 출력 뉴런 1개로 구성되었다. 학습 방법은 학습 데이터 90%, 테스트 데이터 10% 그리고 0.001의 학습률로 100회의 학습을 진행하도록 설정하였다.

(3) 적응형 제어알고리즘 개발

적응형 제어알고리즘은 새로운 환경에 최적 냉매 유량을 산출할 수 있도록 냉매 유량 예측모델을 적응시키는 알고리즘이다. 알고리즘의 내용은 다음과 같다. 시뮬레이션을 통해 n 번째 제어 사이클에서 환경 변수를 추출한다. 추출된 데이터를 예측모델에 입력하여 냉매 유량을 산출한 후 5분의 시뮬레이션을 실시한다. $n+1$ 번째 사이클의 CRAC 토출 공기 온도를 n 번째 사이클의 설정온도와 비교하여 두 값이 같으면 다음 사이클을 진행하고 두 값이 같지 않으면 (식 8)을 통해 최적 냉매 유량을 도출한 후 n 번째 사이클의 환경 변수와 함께 예측모델에 학습시키며 본 과정을 통하여 예측모델은 새로운 환경에 적응해 간다.

제 5 장 적응형 제어알고리즘 성능평가

5.1 개 요

본 장에서는 ‘제 4 장’에서 개발된 냉매 유량 예측모델과 적응형 제어알고리즘의 성능평가를 실시하였다.

냉매 유량 예측모델은 테스트 데이터 세트에서 환경 변수 데이터를 입력 받아 냉매 유량을 예측하며 예측 값은 정답과 비교된다. 이를 통해 통계적 기법으로 예측모델의 정확도를 산출하고 타당성 평가를 실시한다.

예측모델의 최적화는 은닉층과 숨겨진 뉴런 수의 변경을 통해 진행되며 최적화 과정을 거쳐 가장 정확도가 높은 모델은 최종 예측모델로써 채택되고 적응형 제어알고리즘에 내재된다.

적응형 제어알고리즘에서 중요한 것은 기존과 상이한 환경에서의 보정인자 최적화와 시뮬레이션을 통한 적응성 평가이다. 보정인자의 최적화는 값을 일정하게 상승시켜 시뮬레이션을 통해 도출되는 급기온도가 설정온도에 가장 잘 적응하는 값을 채택하며 이는 적응형 제어알고리즘에 적용된다. 제어알고리즘의 적응성 평가는 시스템B에 대한 미학습 상태에서 설정온도 및 회수 풍량을 임의로 변경하는 시뮬레이션을 통해 진행된다. 알고리즘은 실시간 데이터를 바탕으로 자가 학습을 통해 예측모델을 수정하며 측정되는 급기 온도와 설정온도를 비교하여 적응성을 판단한다. 또한 기존 제어 기법인 ON/OFF 시스템 및 보정인자가 제외되어 학습 기능이 없는 비적응형 제어알고리즘과의 비교를 통하여 알고리즘의 안정성과 적응성의 우수성을 입증한다.

5.2 냉매 유량 예측모델 성능평가

5.2.1 초기 예측모델 성능 평가

(1) 평가 기준

인공신경망 모델의 정확도는 입력데이터에 대한 예측 값과 정답의 비교에 의해 평가된다. ASHRAE Guideline 14-2002⁶⁰⁾에서는 시뮬레이션 결과와 실제 값에 대한 비교 평가 기준으로 결정계수(R-Squared, R^2)와 평균 제곱근 오차의 변동계수인 Cv(RMSE) (Coefficient of Variation of the Root-Mean)를 제시하며 두 계수는 (식 9,10)과 같다. R^2 는 예측모델에 대하여 입력 변수와 출력 변수의 상관관계를 의미하며 Cv(RMSE)는 모델의 예측 데이터와 정답 데이터 간의 정밀도를 나타낸다. 따라서 R^2 와 Cv(RMSE)로 변수 간의 상관관계와 초기 예측모델의 성능평가를 실시하며 이후 최적화 결과는 Cv(RMSE)로 정밀도를 판단한다. R^2 는 0.8 이상, Cv(RMSE)는 30% 이하일 때를 적정기준으로 한다.

$$R^2 = \frac{Q - Q_e}{Q} \quad \dots\dots\dots \text{(식 9)}$$

여기서,

Q : 전체 데이터의 편차들을 제공하여 합한 값

Q_e : 전체 데이터의 잔차들을 제공하여 합한 값

60) ASHRAE. (2002). ASHRAE Guideline 14. Measurement of Energy and Demand Savings.

$$Cv(RMSE) = \frac{RMSE}{A} \times 100 (\%) \quad \dots\dots\dots (\text{식 } 10)$$

여기서,

RMSE: 평균 제곱근 오차

A: 정답 냉매 유량의 평균

(2) 초기 예측모델 성능 평가


초기 예측모델은 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 온도, CRAC 회수 공기 풍량을 입력으로 하며 냉매 유량을 출력으로 하는 은닉층 1개, 숨겨진 뉴런 9개의 인공신경망 모델이다. 성능 평가는 테스트 데이터 세트를 예측모델에 대입하여 예측된 냉매 유량과 정답 냉매 유량의 비교를 통해 R^2 및 $Cv(RMSE)$ 로 정밀도를 평가하였다. 그 결과 R^2 와 $Cv(RMSE)$ 는 각각 0.99, 1.05%로 적정기준을 만족시켰다.

5.2.2 예측모델 최적화

(1) 학습률 최적화

Adam 알고리즘은 학습이 진행됨에 따라 스스로 학습률을 수정하지만 초기 학습률 입력 값에 따라 Cost로 표현되는 손실함수 결과 값이 감소한다. 학습률은 초기 값인 0.001에서 0.009까지 0.001씩 증가시켰으며 100회의 학습 회수(Epoch)를 입력하였다. 결과는 <그림 13>과 같다. 학습률 0.001은 학습이 진행됨에 따라 최소 Cost 값인 1.4E-07에 수렴하였다. 학습률 0.002와 0.003은 7.9E-07에 수렴하나 수렴점에 대한 편차가 존재하는 것으로 나타났다. 학습률 0.004부터는 Cost 값이 특정

값에 수렴하지만 학습률 0.001의 Cost 값보다 높거나 불안정하게 수렴하는 모습을 나타내었다. 따라서 최적화 알고리즘의 학습률이 0.001일 때 가장 낮은 Cost 값을 출력하였으며 안정적인 학습이 진행되는 것으로 분석되었다.



*LR: Learning Rate

Fig. 13 학습률 최적화에 따른 Cost 값 변화

(2) 인공신경망 구조 최적화

인공신경망은 은닉층의 수, 숨겨진 뉴런의 수에 따라 학습 정도가 변화한다. 입력과 출력의 관계가 단순한 경우 은닉층과 숨겨진 뉴런의 수가 적어도 좋은 학습 성능을 나타내지만 데이터의 관계는 단순한데 은닉층과 숨겨진 뉴런의 수가 많을 경우에는 예측모델이 복잡해져 오히려 학습 성능이 저조할 수 있다. 따라서 적절한 수의 은닉층과 숨겨진 뉴런의 수를 선정하는 것이 중요하다. 최적화 방법에는 정해진 방법이

없으며 경험적 방법에 의해 진행된다.

본 연구에서는 <표 18>과 같이 초기 모델을 기준으로 은닉층을 1개씩 증가시키고 숨겨진 뉴런의 수는 1개씩 감소 및 증가시켜 예측 값과 정답 간의 비교를 통해 최소의 $Cv(RMSE)$ 를 가지는 구조를 선정하였다. 그 결과 모든 구조에 대해 $Cv(RMSE)$ 가 30% 이하로 적정범위를 만족시키며 높은 성능을 나타내었다. 숨겨진 뉴런이 6개일 때는 은닉층의 수가 1개에서 5개로 증가함에 따라 $Cv(RMSE)$ 가 2.44%, 2.08%, 1.55%, 0.94%로 감소하는 추세를 보였으나 숨겨진 뉴런의 수가 7~12개에서는 은닉층이 증가함에도 $Cv(RMSE)$ 가 전체적으로 감소하지 않았다. 은닉층이 4개일 때부터는 숨겨진 뉴런이 12개 이상으로 증가하였을 시 Cost 값이 수렴하지 않았고 숨겨진 층이 5개 이상일 때 또한 학습이 진행되지 않았다. 이는 인공신경망의 구조가 더 깊어지면 오히려 입력 변수와 출력 변수 사이의 관계를 정의하지 못한다는 것을 의미한다. 따라서 정확도가 가장 높은 예측모델은 $Cv(RMSE)$ 0.47%의 은닉층 4개, 숨겨진 뉴런 11개 모델이며 최종 예측모델로써 적응형 제어알고리즘에 내재된다.

Table 18. 인공신경망 구조별 Cv(RMSE)

(단위, %)

HL HN	1	2	3	4	5
6	2.44	2.08	1.55	0.94	-
7	0.91	0.61	0.51	0.79	-
8	2.64	1.24	0.89	1.00	-
9	1.05	0.80	0.66	1.64	-
10	1.07	2.18	0.50	0.91	-
11	2.57	1.41	0.50	0.47	-
12	2.54	0.62	0.75	-	-

*HL: Hidden Layer, HN: Hidden Neuron

5.3 적응형 제어알고리즘 성능평가

5.3.1 보정인자 최적화

예측모델이 상이한 시스템에 적용되었을 시 해당 시스템에서 요구되는 실내 환경을 제공하기 위해서는 예측값에 대한 오차를 보정해주는 보정인자가 필요하다. 보정인자 α 는 최적유량 도출 식인 (식 8)에 포함되며 온도의 오차에 곱해져 기존 예측 값에 대한 보정된 유량 값을 산출한다. α 값에 따라 보정되는 유량 값은 변화하며 α 값이 클수록 변화의 폭 또한 증가한다. 또한 새로운 시스템에 맞추어 예측모델이 수정될 수 있도록 적절한 보정인자의 선택이 요구되며 최적화 과정을 통해 이를 산출한다.

최적 보정인자의 산출은 α 를 1~2까지 0.2씩 증가 시키며 학습을 진행하였다. 제어알고리즘은 시스템B에 적용되었으며 5분의 제어주기로 학습이 이루어지도록 설정하였다. 예측모델은 시스템B가 아닌 시스템A의

데이터로 학습이 된 상태이며 α 에 의한 오차 수정 과정을 거쳐 설정온도에 가까워진다. 시뮬레이션은 설정온도 24℃, CRAC 토출 공기 온도 24℃를 초기 조건으로 하여 5분 후에 설정온도를 20℃로 변경하였으며 모든 보정인자에 대해 100회의 학습을 실시하였다. 시뮬레이션 개요는 <표 19>와 같다.

Table 19. 보정인자 최적화 시뮬레이션 개요

구 분	내 용	
보정인자(α)	$\alpha = 1.0, 1.2, 1.4, 1.6, 1.8, 2.0$	
제어주기	5min	
학습 횟수	100회	
시뮬레이션 조건	초기조건	설정온도 24℃, 실내 온도 24℃
	변경조건	설정온도 20℃ (5min)

보정인자 변경에 따른 CRAC 토출 공기 온도 및 설정온도와의 오차는 <표 20,21>과 같다. 적응성 평가는 설정온도와 CRAC 토출 공기 온도를 비교하여 오차제곱 평균의 제곱근인 Root Mean Square Error (RMSE)로 실시하였다. RMSE는 시뮬레이션에서 예측 값과 실제 값을 비교할 때 자주 사용되는 통계적 지표이며 오차가 적을수록 정밀도가 높다. 학습이 완료된 시점을 특정 짓는 지표가 없으므로 설정온도가 변경된 300초에서 시뮬레이션 종료 시점까지를 범위로 설정하였다.

오차는 CRAC 토출 공기 온도에서 설정온도를 뺀 값이다. 보정인자가 1.0에서 2.0으로 변화함에 따라 각 시간대 별 CRAC 토출 공기 온도가 증가하는 모습을 나타내었다. 그러나 20분까지는 설정온도 20℃에 맞추어 CRAC 토출 공기 온도가 각각 19.97℃, 20.01℃, 20.04℃, 20.07℃, 10.10℃,

20.13℃로 증가하였으나 이내 다시 감소하여 오차의 절댓값이 증가하였고 같은 현상이 35분, 55분에도 반복되었다. 온도의 증가와 감소는 <그림 14>와 같이 제어에 있어 설정온도를 찾아가는 과정에 발생하는 헌팅현상(Hunting)이며 시뮬레이션이 진행됨에 따라 <그림 15>와 같이 오차의 절댓값은 점차 감소한다. 또한 α 의 각 경우에 대하여 음수 값은 10개, 9개, 9개, 9개, 7개, 5개로 감소하였으며 이는 보정인자의 값이 커지면 보정되는 유량 값이 증가해 CRAC 토출 공기 온도에 더 큰 영향을 주는 것을 의미한다. 따라서 시뮬레이션 결과에 의해 설정온도 변경 이후의 RMSE 값이 1.408로 가장 낮은 보정인자 2.0이 채택되었다.

단, 해당 보정인자는 시뮬레이션을 실시한 조건의 최적 보정인자이며 실내 환경이 달라질 경우의 절대적인 최적 값이 아니다. 이는 추후 연구로써의 해결과제이며 본 연구는 적응형 제어알고리즘의 구동 및 성능평가가 목적이므로 $\alpha = 2.0$ 을 적용한다.

Table 20. 보정인자($\alpha=1.0, 1.2, 1.4$) 에 따른 급기온도 및 오차

시 간 (min)	$\alpha = 1.0$		$\alpha = 1.2$		$\alpha = 1.4$	
	$T_{SA}(^{\circ}\text{C})$	Error	$T_{SA}(^{\circ}\text{C})$	Error	$T_{SA}(^{\circ}\text{C})$	Error
10	16.08	-3.92	16.08	-3.92	16.08	-3.92
15	18.03	-1.97	18.05	-1.95	18.07	-1.91
20	19.97	-0.03	20.01	0.01	20.04	0.04
25	18.90	-1.10	18.95	-1.05	18.99	-1.01
30	19.69	-0.31	19.75	-0.25	19.81	-0.19
35	19.34	-0.66	19.41	-0.59	19.48	-0.52
40	19.64	-0.36	19.72	-0.28	19.80	-0.20
45	19.60	-0.40	19.69	-0.31	19.78	-0.22
50	19.71	-0.29	19.81	-0.19	19.90	-0.10
55	19.66	-0.34	19.77	-0.23	19.86	-0.14
RMSE	1.465		1.447		1.433	

Table 21. 보정인자($\alpha=1.6, 1.8, 2.0$) 에 따른 급기온도 및 오차

시 간 (min)	$\alpha = 1.6$		$\alpha = 1.8$		$\alpha = 2.0$	
	$T_{SA}(^{\circ}\text{C})$	Error	$T_{SA}(^{\circ}\text{C})$	Error	$T_{SA}(^{\circ}\text{C})$	Error
10	16.08	-3.92	16.08	-3.92	16.08	-3.92
15	18.08	-1.92	18.10	-1.90	18.12	-1.88
20	20.07	0.07	20.10	0.10	20.13	0.13
25	19.03	-0.97	19.08	-0.92	19.12	-0.88
30	19.86	-0.14	19.92	-0.08	19.97	-0.03
35	19.54	-0.46	19.61	-0.39	19.67	-0.33
40	19.88	-0.12	19.95	-0.05	20.02	0.02
45	19.86	-0.14	19.95	-0.06	20.01	0.01
50	19.98	-0.02	20.06	0.06	20.14	0.14
55	19.95	-0.05	20.03	0.03	20.10	0.10
RMSE	1.422		1.414		1.408	




Fig. 14 보정인자 변화에 따른 CRAC 토출 공기 온도 변화




Fig. 15 보정인자 변화에 따른 오차 절댓값 변화

5.3.2 적응성 성능평가

(1) 적응성 성능평가 개요

적응형 제어알고리즘의 성능평가는 설정온도와 서버 풍량을 다양하게 변경시켜 시스템B의 시뮬레이션을 통해 실시하였다. 적응형 제어알고리즘에 포함되는 냉매 유량 예측모델은 시스템A에 학습이 되어있는 상태이며 시스템B에 적용되었을 때 학습을 통하여 CRAC 토출 공기 온도가 설정온도를 만족하는지를 파악한다. 비교 대상으로는 기존에 사용되는 ON&OFF 시스템, 그리고 냉매 유량 예측모델이 적용되었으나 보정인자가 제외되어 새로운 환경에 대한 학습 기능이 없는 비적응형 제어알고리즘을 선정하였다.

ON&OFF 시스템은 자동 제어방식의 한 종류로 제어 대상을 목표 값으로 유지시키기 위하여 조작량을 끄고 켜는 과정을 반복한다. 일반적으로 목표 값에 $\pm$ 오차 값을 주어 데드밴드(Dead-band)를 설정하며 데드밴드가 없으면 목표치 근처에서 계속적으로 시스템 가동과 미가동을 반복하기 때문에 설비에 무리가 가고 제어가 불안정하다.

본 연구에서는 Python으로 ON&OFF 시스템을 구현하였다. 데드밴드 오차는 설정온도로부터 $\pm 1^{\circ}\text{C}$ 차이가 나도록 설정하였으며 시스템 가동 시의 냉매 유량은 280 kg/hr 이다. 제어주기에서 데이터를 취득하여 CRAC 토출 공기 온도가 데드밴드 이하면 시스템을 미가동시키고 데드밴드 이상이면 시스템을 가동시킨다. 예로써, n 번째 사이클의 설정온도가 24°C 이고 CRAC 토출 공기 온도가 22°C 이면 시스템이 미가동 상태로 변경되고 CRAC에 회수되는 공기의 온도가 그대로 CRAC 토출 공기 온도에 입력된다. 반면 설정온도가 24°C 이고 CRAC 토출 공기 온도가 26°C 이면 시스템이 가동 상태로 변경되어 (식 2)에 의해 다음 제어 사이클을 위한 CRAC 토출 공기 온도가 산출되어 입력된다.

비적응형 제어알고리즘은 상이한 데이터센터 모델에 제어알고리즘이 적용되었을 시 오차의 보정으로 인한 학습이 진행되지 않도록 보정인자를 제외하여 냉매 유량 예측모델의 영향만 존재하도록 구성한 알고리즘이다. 적응형 제어알고리즘과 비적응형 제어알고리즘의 비교를 통하여 새로운 환경에 대한 학습 여부의 차이점을 비교하기 위해 구성하였다.

적응성 평가를 위한 시뮬레이션 시나리오는 설정온도 고정 · 풍량 고정, 설정온도 변경 · 풍량 고정, 설정온도 고정 · 풍량 변경, 설정온도 변경 · 풍량 변경으로 총 4가지이다. 시뮬레이션 개요는 <표 22>와 같다. 설정온도 고정의 온도는 24℃이며 매 10시간 기준 20℃, 26℃, 24℃로 변경된다. 풍량 고정에서의 풍량은 서버의 절반이 고발열 상태인 0.479 kg/hr이며 각 CRAC 토출 풍량에 입력된다. 풍량 변화 시 풍량은 30분 단위로 변경되며 저발열에서 고발열로 변경되는 서버의 개수는 난수 생성을 통해 설정하였다. 이때 서버의 개수는 모든 시나리오에 동일하게 적용된다. 변경되는 서버의 수는 <표 22>의 Server Mass Flow Rate Variations와 같다. 데이터취득 및 신호 입력을 위한 제어주기는 5분이며 총 30시간의 시뮬레이션을 진행하였다.

Table 22. 적응성 평가를 위한 시스템B 시뮬레이션 개요

구 분		내 용					
Time Step		100 sec					
Iteration		10					
Simulation Cycle		1 cycle = 300 sec					
Simulation Time		30 hours					
Setpoint Temperature Variations	10hours after simulation begins	20℃					
	20hours after simulation begins	26℃					
	30hours after simulation begins	24℃					
Server Mass Flow Rate Variations	Number of High Heat Servers per every 30 minutes	Number of Servers					
		0~5hr	5~10hr	10~15hr	15~20hr	20~25hr	25~30hr
		10	13	10	6	8	9
		6	4	8	12	20	6
		12	8	16	13	13	14
		14	14	14	13	6	12
		12	5	11	8	10	14
		6	18	20	12	17	12
		10	7	7	4	8	4
		20	12	8	6	16	13
		14	16	17	13	6	8
		8	5	5	10	10	12

(2) 적응성 성능평가

적응성 성능평가는 ON&OFF 시스템, 비적응형 제어알고리즘, 적응형 제어알고리즘을 4가지 시나리오인 설정온도 고정 · 풍량 고정(Case 1), 설정온도 변경 · 풍량 고정(Case 2), 설정온도 고정 · 풍량 변경(Case 3), 설정온도 변경 · 풍량 변경(Case 4)에 대한 RMSE, 오차의 절댓값, CRAC 토출 공기 온도 추세파악을 통하여 실시하였다.

각 시스템의 RMSE는 시간에 따른 과도상태와 정상상태의 차이를 파악하기 위해 케이스 별 5시간 단위로 산출하였으며 <표 24>와 같다. 오차는 설정온도와 CRAC 토출 공기 온도의 차이이다. ON&OFF 시스템의 경우 각 케이스에 대해 평균 RMSE가 각각 5.02, 5.07, 4.96, 5.04로 도출되었으며 비적응형 제어알고리즘은 0.70, 0.72, 0.97, 0.97, 적응형 제어알고리즘은 0.16, 0.73, 0.30, 0.69로 산출되었다. ON&OFF 시스템의 RMSE가 두 시스템에 비해 높게 산출되는 이유는 잦은 시스템 가동상태 변경 및 냉매 유량 값의 2위치 적용으로 미가동 시에는 0 kg/hr, 가동 시에는 280 kg/hr의 유량이 적용되었기 때문이다. 설정온도가 20℃인 경우 미가동 시에는 약 30~33℃의 CRAC 회수 공기 온도가 토출되었으며 가동 시에는 약 19~23℃의 온도가 토출되었다. 설정온도가 26℃인 경우 시스템 미가동, 가동 시의 온도는 각각 32~34℃, 20~23℃가 토출되었으며, 설정온도가 24℃일 때는 각각 31~35℃, 18~22℃로 시스템 가동 유무에 따라 온도의 편차가 큰 것으로 분석되었다. 이는 곧 2위치 냉매 유량 적용으로는 CRAC 토출 공기 온도가 설정온도를 만족시킬 수 없음을 의미한다.

Case 1, Case 3, Case 4에 대해서는 적응형 제어알고리즘의 평균 RMSE가 0.16, 0.30, 0.69로 가장 낮았으나 Case 2는 비적응형 제어알고리즘의 평균 RMSE가 0.72로 적응형 제어알고리즘의 평균

RMSE인 0.73보다 낮았다. 이는 10시간 마다 설정온도가 변화할 때 설정온도와 CRAC 토출 공기 온도 사이에 큰 오차가 생기며 적응형 제어알고리즘의 경우 과도상태가 나타나기 때문이다. <표 23>의 최대 온도 오차에 의하면 Case 2에서 비적응형 제어알고리즘의 최대 온도 오차는 6.52℃이며 적응형 제어알고리즘의 최대 온도 오차는 8.67℃로 나타남을 알 수 있다.

하지만 Case 2의 5시간 단위 RMSE 분석 결과 설정온도가 변화하는 10시간, 20시간, 30시간에서 비적응형 제어알고리즘의 경우 앞선 5시간과 이후 5시간은 RMSE의 차이가 크게 나지 않지만 적응형 제어알고리즘은 앞선 5시간의 RMSE가 각각 1.16, 1.54, 0.79에서 이후 5시간은 0.38, 0.36, 0.16으로 감소하였다. 이는 시간이 지남에 따라 환경에 대한 학습에 의해 오차가 감소하기 때문이며 Case 2의 평균 RMSE가 비적응형 제어알고리즘보다 높게 산출되는 이유는 설정온도가 변경되는 앞선 5시간의 오차가 크기 때문이다.

Table 23. 시스템 및 Case 별 최대 온도 오차 절댓값 (단위, ℃)

구 분	Case 1	Case 2	Case 3	Case 4
	Max. Error	Max. Error	Max. Error	Max. Error
ON&OFF	9.68	9.71	9.69	9.93
비적응형 제어알고리즘	0.71	6.52	2.50	7.97
적응형 제어알고리즘	0.71	8.67	1.55	5.93

Table 24. 시스템 및 Case 별 RMSE

구 분	시간 (hr)	시스템 별 RMSE		
		ON&OFF	비적응형 제어알고리즘	적응형 제어알고리즘
Case 1	0~5	4.97	0.70	0.35
	6~10	5.01	0.70	0.12
	11~15	5.05	0.70	0.12
	16~20	5.03	0.70	0.12
	21~25	5.09	0.70	0.11
	26~30	4.94	0.70	0.12
	평균	5.02	0.70	0.16
Case 2	0~5	5.06	0.71	1.16
	6~10	5.04	0.78	0.38
	11~15	5.01	0.73	1.54
	16~20	5.17	0.72	0.36
	21~25	4.94	0.69	0.79
	26~30	5.21	0.69	0.16
	평균	5.07	0.72	0.73
Case 3	0~5	4.90	0.93	0.46
	6~10	4.92	1.02	0.27
	11~15	5.25	0.91	0.33
	16~20	4.95	1.02	0.22
	21~25	4.83	0.95	0.27
	26~30	4.93	0.97	0.23
	평균	4.96	0.97	0.30
Case 4	0~5	4.94	0.91	1.15
	6~10	5.27	1.04	0.51
	11~15	5.19	0.94	1.14
	16~20	5.00	1.03	0.30
	21~25	4.95	0.5	0.82
	26~30	4.91	0.97	0.22
	평균	5.04	0.97	0.69

Table 25. 케이스별 5시간 단위 RMSE 변동 그래프

구 분	5시간 별 RMSE 변동 그래프
Case 1	Figure 1: Case 1 RMSE graph. The x-axis is 'Time Steps (hr)' from 5 to 30. The y-axis is 'RMSE' from 0 to 6. The 'ON&OFF' series (dashed) is around 5. The '미학습 제어알고리즘' series (dotted) is constant at 1. The '적응형 제어알고리즘' series (solid) starts at 0.5 and decreases to 0 by step 10.
Case 2	Figure 2: Case 2 RMSE graph. The x-axis is 'Time Steps (hr)' from 5 to 30. The y-axis is 'RMSE' from 0 to 6. The 'ON&OFF' series (dashed) is around 5. The '미학습 제어알고리즘' series (dotted) is constant at 1. The '적응형 제어알고리즘' series (solid) fluctuates between 0.5 and 1.5.
Case 3	Figure 3: Case 3 RMSE graph. The x-axis is 'Time Steps (hr)' from 5 to 30. The y-axis is 'RMSE' from 0 to 6. The 'ON&OFF' series (dashed) is around 5. The '미학습 제어알고리즘' series (dotted) is constant at 1. The '적응형 제어알고리즘' series (solid) starts at 0.5 and decreases to 0 by step 10.
Case 4	Figure 4: Case 4 RMSE graph. The x-axis is 'Time Steps (hr)' from 5 to 30. The y-axis is 'RMSE' from 0 to 6. The 'ON&OFF' series (dashed) is around 5. The '미학습 제어알고리즘' series (dotted) is constant at 1. The '적응형 제어알고리즘' series (solid) fluctuates between 0.5 and 1.5.

ON&OFF 시스템의 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 풍량의 관계는 <그림 16~19>와 같다. Case 2, Case 4의 경우 설정온도가 20℃, 26℃, 24℃로 변경됨에 따라 CRAC 토출 공기 온도 또한 비례하여 변화하였으며 풍량이 일정하기 때문에 온도의 최대, 최소값 또한 비교적 일정하게 분포하였다. 그러나 Case 3, Case 4와 같은 풍량 변화 시 최대, 최소 CRAC 토출 공기 온도 또한 불규칙하게 나타났으며 설정온도를 만족시키지 못했다.

비적응형 제어알고리즘의 설정온도, CRAC 토출 공기 온도, CRAC 회수 공기 풍량의 관계는 <그림 20~23>과 같다. 네 개의 Case에 대하여 CRAC 토출 공기 온도는 설정온도와 풍량에 비례하는 것으로 나타났다. 이는 설정온도가 증가하면 예측모델의 예측 냉매 유량이 감소하고 풍량 증가 시 예측 냉매 유량이 증가하는 비례 관계가 잘 성립되었음을 의미한다. 그러나 모든 Case에 대해 CRAC 토출 공기 온도는 설정온도에 근접하였으나 변경 값인 20℃, 26℃, 24℃ 보다 낮은 값이 출력되었으며 설정 값에 맞춰 가는 도중 발생하는 과도상태 및 정상상태의 상태 구분이 나타나지 않았다. 전체적으로 CRAC 토출 공기 온도가 설정온도보다 낮게 도출되는 현상은 시스템A에 대한 학습만 이루어진 예측모델의 경우 시스템A의 규모가 시스템B에 비해 크기 때문에 예측 냉매 유량 값 또한 시스템B에서 요구하는 냉매 유량보다 크기 때문인 것으로 파악된다.

<그림 24~27>은 적응형 제어알고리즘에서의 설정온도와 CRAC 토출 공기 온도, CRAC 회수 공기 풍량의 관계를 나타낸다. 모든 케이스에서 비적응형 제어알고리즘과 비교하여 풍량의 변화에 대한 CRAC 토출 공기 온도의 변화는 크지 않았다. 설정온도가 변경되었을 시에는 적응과정의 과도상태와 적응 후에 설정 값에 수렴하는 정상상태의 상태 구분이 나타났다. <그림 25>에 나타난 Case 2와 <그림 27>의 Case 4에서 해당

현상이 뚜렷하게 관찰된다. 설정온도가 변경되는 경우 공통적으로 CRAC 토출 공기 온도가 크게 감소한 후 다시 상승하는 오버슈트(Overshoot)현상이 발생한다. 과도상태에 있어 오버슈트는 흔하게 발생하는 현상이지만 초기 토출 온도의 감소현상은 해당 상황에 대한 학습이 아직 이루어지지 않은 상태이기 때문에 시스템A에서 학습된 큰 값의 냉매 유량이 도출되었기 때문이다. Case 2 과도상태에서 설정온도 이상일 시 최대 온도 오차는 온도 변화 구간에 따라 각각 4.74°C , 8.67°C , 2.04°C 이며 설정온도 이하의 최대 온도 오차는 1.46°C , 6.46°C , 0.66°C 이다. 또한 Case 4에서는 과도상태 오차에 대해 설정온도 이상일 경우 4.63°C , 1.19°C , 2.26°C 이며 설정온도 이하인 경우는 1.38°C , 5.93°C , 0.67°C 로 나타났다. 그러나 정상상태에서는 학습이 진행됨에 따라 Case 2의 경우 평균 온도 오차가 0.12°C , 0.13°C , 0.02°C 로 감소하였으며 Case 4는 각각 0.13°C , 0.09°C , 0.05°C 로 감소하였다.

환경 변수의 변화에 대한 적응성 추이는 <그림 26> Case 3에 잘 나타난다. 설정온도가 고정된 상태에서 서버의 고발열 개수가 동일한 230~260분 구간, 770~800분 구간, 1260~1290분 구간의 오차 절댓값의 평균은 각각 0.43°C , 0.21°C , 0.08°C 로 감소하였다. 이는 보정인자로 수정된 냉매 유량이 학습되어 예측모델이 업데이트된 것을 의미한다.

<그림 28~31>은 각 Case 별 비적응형 제어알고리즘 및 적응형 제어알고리즘의 설정온도와 CRAC 토출 공기 온도 간의 오차를 절댓값으로 나타낸 것이다. 온도 오차 분석 결과 Case 2와 Case 4에 대하여 온도의 오차가 크게 나타났다. Case 2에서는 적응형 제어알고리즘에 대해 최대 온도 오차가 8.67°C , Case 4에서는 비적응형 제어알고리즘에서 최대 온도 오차가 7.97°C 이다. Case 2에서의 적응형 제어알고리즘 최대 온도 오차 발생 이유는 과도상태에서 CRAC 토출

공기 온도가 설정온도를 만족시키기 위해 냉매 유량이 감소해야하나 과도하게 감소했기 때문이며 해당 상황에 대해 보정인자가 최적 값이 아니기 때문인 것으로 판단된다. 또한 Case 4의 경우 비적응형 제어알고리즘에서의 최대 온도 오차가 나타나는 이유는 10시간째의 제어주기에서 설정온도가 20℃에서 26℃로 변경되었으나 토출되고 있던 공기의 온도는 이전 사이클에서 토출된 공기의 온도이므로 당시의 온도 오차가 크기 때문이다.

비적응형 제어알고리즘의 경우 모든 케이스에서 오차의 절댓값이 0으로 수렴하지 않았으며 오차가 감소하는 모습이 아닌 각 Case에 대해 불규칙적으로 산출되었다. 반면 적응형 제어알고리즘은 환경 변수의 변화가 있는 제어주기에서는 오차가 증가하였으나 시간이 지남에 따라 0에 수렴하는 추세를 보였다. 이는 비적응형 제어알고리즘은 시뮬레이션이 계속됨에도 새로운 환경인 시스템B의 설정 조건을 만족시키지 못하며, 예측모델 만으로는 상이한 환경에 대한 적응성은 없는 것을 의미한다. 이와 달리 적응형 제어알고리즘은 오차를 최소화 하는 학습을 거쳐 시스템B에 적응하는 결과를 나타냈다.




Fig. 16 ON&OFF 시스템 설정온도 고정 & 풍량 고정




Fig. 17 ON&OFF 시스템 설정온도 변경 & 풍량 고정




Fig. 18 ON&OFF 시스템 설정온도 고정 & 풍량 변경




Fig. 19 ON&OFF 시스템 설정온도 변경 & 풍량 변경




Fig. 20 비적응형 제어알고리즘 설정온도 고정 & 풍량 고정




Fig. 21 비적응형 제어알고리즘 설정온도 변경 & 풍량 고정




Fig. 22 비적응형 제어알고리즘 설정온도 고정 & 풍량 변경




Fig. 23 비적응형 제어알고리즘 설정온도 변경 & 풍량 변경




Fig. 24 적응형 제어알고리즘 설정온도 고정 & 풍량 고정




Fig. 25 적응형 제어알고리즘 설정온도 변경 & 풍량 고정




Fig. 26 적응형 제어알고리즘 설정온도 고정 & 풍량 변경




Fig. 27 적응형 제어알고리즘 설정온도 변경 & 풍량 변경




Fig. 28 Case 1에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차




Fig. 29 Case 2에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차




Fig. 30 Case 3에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차




Fig. 31 Case 4에 대한 비적응형 제어알고리즘 및 적응형 제어알고리즘의 온도 오차

5.4 소결

본 장에서는 개발된 예측모델과 보정인자의 최적화 그리고 적응형 제어알고리즘의 성능평가를 실시하였다. 최적화된 예측모델과 보정인자는 적응형 제어알고리즘에 내재되었다. 이후 ON&OFF 시스템, 비적응형 제어알고리즘, 적응형 제어알고리즘을 시스템B에 적용하여 시뮬레이션 결과를 통해 각 시스템의 특성을 비교·분석을 실시하였으며 설정온도와 CRAC 토출 공기 온도에 대한 RMSE, 최대 오차, 환경 변수의 변경에 따른 온도 변화 및 오차의 추세를 파악하였다.

초기 예측모델의 최적화는 학습률 및 인공신경망 구조에 대해 진행되었다. 그 결과 은닉층 4개, 숨겨진 뉴런 11개 모델이 Cv(RMSE) 0.47%로 ASHRAE 권장 기준을 만족시키며 가장 높은 정확도를 나타냈다.

보정인자의 최적화는 α 를 변화시키며 시스템B의 설정온도와 풍량을 고정시킨 상태에서 시뮬레이션을 진행하였다. RMSE로 설정온도와 CRAC 토출 공기 온도의 오차를 판단하였으며 $\alpha = 2.0$ 일 때 RMSE 1.408으로 모든 경우에 대하여 가장 정확도가 높았다. 따라서 해당 보정인자를 적응형 제어알고리즘에 적용하였다.

적응형 제어알고리즘의 적응성 성능평가는 ON&OFF 시스템, 비적응형 제어알고리즘과 비교되어 실시되었으며 각 시스템에 대해 4가지의 동일한 시나리오로 시뮬레이션을 수행하였다. 그 결과 ON&OFF 시스템은 세 시스템 중 각 Case에 대한 평균 RMSE가 5.02, 5.07, 4.96, 5.04로 가장 높게 나타났으며 비적응형 제어알고리즘은 0.70, 0.72, 0.97, 0.97, 적응형 제어알고리즘은 0.16, 0.73, 0.30, 0.69로 산출되었다. 단, Case 2에 대해서는 적응형 제어알고리즘의 RMSE가 비적응형 제어알고리즘보다

RMSE가 높았는데 이는 적응 과정에서 과도상태의 오차 때문인 것으로 분석되었다. 온도와 풍량의 관계에서는 보정인자 제외 예측모델의 경우 CRAC 토출 공기 온도가 설정 값에 근접하였으나 오차가 0으로 수렴하지 못하였고 적응형 제어알고리즘은 환경 변수 변경이 있을 시 온도에 오차가 존재하였으나 학습이 진행됨에 따라 오차가 0으로 수렴하였다. 이에 따라 적응형 제어알고리즘의 학습 과정을 확인할 수 있었으며 새로운 시스템에 적용되어도 최적 냉매 유량을 도출하여 설정 온도에 맞는 실내 환경을 제공할 수 있는 가능성을 확인하였다.

제 6 장 결 론

최근 데이터 관련 산업의 증가로 인해 IT 장비 및 관리 시설인 데이터센터에 대한 수요가 급증하고 있다. 데이터센터는 전 세계 전력 소비량의 2%를 차지하며 운영 및 관리에 있어 약 50%가 냉각 시스템에 사용되고 있다. 데이터센터 에너지 절감을 위해 냉각 시스템의 효율적 운영은 필수적이며 국내 상황에 맞는 해결책이 필요하다. 따라서 본 연구에서는 수냉식 시스템에 대해 적용이 가능한 냉매 유량 예측모델 및 적응형 제어알고리즘의 개발을 통해 새로운 환경에 대해서도 최적의 실내 환경을 제공할 수 있도록 하였다.

연구 과정은 관련 기술을 파악을 통한 명확한 목표 및 범위 설정, 데이터 취득 및 실험을 위한 CFD 모델링, 냉매 유량 예측 모델 및 적응형 제어알고리즘의 개발, 최적화 및 성능평가의 순으로 진행하였으며 결과에 대한 자세한 내용은 다음과 같다.

(1) 냉매 유량 예측모델 개발 및 최적화

냉매 유량 예측모델은 데이터센터 실내 환경 변수 간의 복잡한 관계를 정의하기 위하여 인공신경망을 통해 개발되었다. 초기모델은 은닉층 1개, 숨겨진 뉴런 9개 구조를 가지며 학습 함수로는 Adam 최적화 알고리즘을 사용하였다. 이후 학습률과 인공신경망 구조의 최적화 과정을 통해 학습률 0.001, 은닉층 4개, 숨겨진 뉴런 11개의 모델이 Cv(RMSE) 0.47%의 가장 우수한 성능을 보이며 최종 냉매 유량예측모델로 채택되었다.

(2) 보정인자 최적화 및 적응형 제어알고리즘 구축

일반 예측모델이 새로운 데이터센터 시스템에 적용되기 위해서는 예측값에 대한 오차를 피드백 해주는 장치가 필요하며 이를 보정인자를 적용함으로써 새로운 환경에 대한 재학습의 기능을 부여하였다. 보정인자 α 는 1.0부터 2.0까지 0.2씩 변경해 가며 시스템B에 대하여 테스트를 진행하였다. 그 결과 $\alpha = 2.0$ 가 RMSE 1.408로 가장 높은 정확도를 나타냈으며 해당 보정인자와 개발된 최종 냉매 유량예측모델이 적응형 제어알고리즘에 포함되었다.

적응형 제어알고리즘은 n 번째 사이클의 환경 변수에 의한 결과를 $n+1$ 번째 사이클과 비교하여 CRAC 토출 공기 온도가 설정온도와 다를 경우 새로운 냉매 유량을 도출하여 n 번째 사이클의 환경 변수와 함께 재학습이 이루어지도록 구성하였다.

(3) 적응형 제어알고리즘 성능평가

적응형 제어알고리즘의 성능평가는 기존에 사용되는 ON&OFF 시스템과 보정인자가 제외되어 재학습의 기능이 없는 비적응형 제어알고리즘과의 비교를 통하여 실시하였다. 설정온도 고정 · 풍량 고정, 설정온도 변경 · 풍량 고정, 설정온도 고정 · 풍량 변경, 설정온도 변경 · 풍량 변경의 4가지 경우의 시나리오가 각 제어시스템에 동일하게 적용되어 시스템B로 시뮬레이션이 진행되었다. 그 결과 ON&OFF 시스템은 각 Case에 대한 평균 RMSE가 5.02, 5.07, 4.96, 5.04로 가장 성능이 낮았으며 비적응형 제어알고리즘은 0.70, 0.72, 0.97, 0.97, 적응형 제어알고리즘은 0.16, 0.73, 0.30, 0.69로 도출되었다. 각 Case 별 온도 오차 추세 분석 결과 설정온도의 변경이 일어난 제어주기에 온도 오차가 크게 발생하였으며 풍량의 변화에 대해서는 큰 오차가 발생하지 않음을 파악하였다. 그러나 모든 경우에

대하여 비적응형 제어알고리즘은 오차가 0에 수렴하지 못했으나 적응형 제어알고리즘은 학습이 진행됨에 따라 오차가 0에 수렴하였다. 비적응형 제어알고리즘은 Case 1, Case 2의 경우 온도 오차가 약 0.48°C 로 일정한 오차를 나타냈으나 Case 3, Case 4는 풍량 변화에 따라 온도의 오차도 지속적으로 변화하며 설정온도를 만족시키지 못하였다. 반면 적응형 제어알고리즘은 과도상태에서 온도 오차가 비적응형 제어알고리즘에 비해 크게 나타났으나 정상상태에서는 설정온도인 20°C , 26°C , 24°C 를 만족시켜 학습이 진행됨에 따라 높은 성능을 나타냈다.

따라서 개발된 적응형 제어알고리즘은 새로운 시스템의 환경 변수 학습을 통해 설정온도 및 풍량 변화에 대한 최적의 CRAC 토출 공기 온도를 만족시킬 수 있음을 확인할 수 있었다. 이에 추후 실제 데이터센터 적용 시 변동하는 냉방부하에 대하여 우수한 성능으로 IT 장비의 안정적인 운영 및 최적 실내 열환경 제어를 제공할 수 있을 것으로 사료된다. 또한 냉방 에너지의 효율적 운영을 통해 데이터센터의 에너지 절감 및 CO_2 배출량 감소를 달성하여 그린 데이터센터 구현에 핵심 요소로써 적용될 수 있을 것으로 판단된다.

본 연구는 실제 데이터센터의 데이터를 취득하여 연구를 진행한 것이 아닌 시뮬레이션을 활용하여 데이터를 취득하였고 각종 시스템 및 환경 변수의 상호작용을 수학적 모델로써 모사했다는 점에 한계가 있다. 또한 보정인자의 경우 본 연구에서 최적화는 특정 환경에 대해서만 진행된 것이므로 환경 변수가 불규칙적으로 변화하는 실제 시스템에서는 보정인자의 변경 또한 고려해야한다. 이는 추후 연구로 보완되어야 하며 예측모델 또한 실제 데이터센터 데이터에 의해 재학습이 이루어져야 할 것으로 사료된다.

참 고 문 헌

<국내문헌>

1. 박승민. (2017). 4차 산업혁명 주요 테마 분석. 통계청 2017년 하반기 연구 보고서 제 3권.
2. 조진균 (2008). 고밀도 데이터센터의 공조효율 및 에너지성능 개선을 위한 공조시스템 계획방법 연구, 연세대학교 박사학위논문.
3. 정산진, 김문구. (2013). 그린 데이터센터 표준화 및 인증제 동향. 한국정보통신기술협회.
4. 원종연 (2004). 외기냉수냉방 시스템의 에너지 절약효과에 관한 연구, 중앙대학교 석사학위논문.
5. 방송통신위원회 국립전파연구원. (2012). 그린 데이터 센터 구축 지침. 방송통신표준 KCS.KO-09.0065.
6. 미래창조과학부. (2015). 데이터센터 산업 육성을 위한 기반조성 연구·조사. 방송통신정책연구. 15-진흥-003.
7. 한국IT서비스산업협회. (2008). 데이터센터의 정의와 분류체계.
8. 김민휘. (2014). 데이터 센터의 최신 공조시스템과 제어기술. 한국건축친환경설비학회 건축환경설비 8(1), 25-33.
9. 김재현, 이진영, 조진균. (2013). 그린데이터센터 구현을 위한 가이드라인 연구. 대한설비공학회 하계학술발표대회 논문집, 439-442.
10. 연창근, 이진영. (2016). 네이버 데이터센터 ‘각’. 건축환경설비, 10(3), 51-57.
11. 조진균, 홍민호, 성노천, 정차수, 김병선. (2006). 데이터센터의 합리적인 환경제어를 위한 부하패턴 분석 및 에너지소비량 산정에 관한 연구. 대한설비공학회 학술발표대회논문집, 458-463.
12. 조진균, 차지형, 홍민호, 연창근. (2008). 데이터센터의 합리적인 환경제어를 위한 공기분배 시스템에 대한 연구. 대한설비공학회 학술발표대회논문집, 487-492.

13. 조진균, 정차수, 김병선. (2008). 최적 IT환경제어를 위한 데이터센터의 냉각(열원)시스템 산정에 관한 연구. 대한건축학회 논문집, 계획계, 24(12), 313-320.
14. 박병윤, 정용호. (2013). 가변풍량제어시스템과 냉복도밀폐시스템의 적용에 의한 데이터센터의 냉방에너지 절감 효과 분석. 한국건축친환경설비학회 논문집, 7(3), 185-192.
15. 함상우, 김민휘, 윤동섭, 정재원. (2014). 컨테이너먼트가 적용된 모듈러 데이터센터의 공조 팬 제어 방안에 관한 실험적 연구. 대한건축학회 학술발표대회 논문집, 34(2), 285-286.
16. 김제영. (2015). 데이터센터의 냉방에너지 사용량 감축을 위한 에너지 절약형 공조시스템 개발. 홍익대학교 석사학위논문.
17. 오보영, 김영일, 김선훈. (2017). 데이터센터의 CFD 해석을 통한 공기분배 방식별 공조시스템 비교 연구. 대한설비공학회 학술발표대회논문집, 164-167.
18. 조진균, 박병용, 정용대, 김영팔, 우제상. (2019). 데이터센터 공조·냉각시스템 효율개선을 위한 실험적 연구 :룸 단위에서 구역 단위 공조·냉각방식 변경을 중심으로. 대한설비공학회 논문집, Vol.31, 32-44.
19. 안주현, 이우영, 정대수, 이형진. (2018). 제로에너지 타운을 위한 딥러닝 에너지 수요/공급 예측 시스템 설계. 2018년도 한국통신학회 하계종합학술발표회 논문집, 573-574.
20. 강인성. (2017). 오피스건물 공조시스템의 인공지능경망 기반 에너지사용량 예측모델 개발. 중앙대학교 석사학위논문,
21. 조운환, 서영덕, 박대준, 정제창. (2016). DNN에서 효율적인 학습을 위한 활성화 함수에 대한 고찰. 대한전자공학회 학술대회, 800-803.
22. 최은지. (2019). 딥러닝 기반 재실자 포즈별 MET 산출모델 개발. 중앙대학교 석사학위 논문.

<국외문헌>

1. Whitehead, B., Andrews, D., Shah, A., & Maidment, G. (2014). Assessing the Environmental impact of data centres. Part 1: Background, energy use and metrics, Building and Environment, Vol. 82, 151-159.
2. Info-Tech Research Group. (2007). Top 10 Energy-Saving Tips for a Greener Data Center. Operate & Optimize Info-tech Advisor Premium.
3. ASHRAE. (2010) Green Tips for Data Centers. ASHRAE Datacom Series 10.
4. Tony Evens. (2004). The Different Types of Air conditioning Equipment for IT Environments. APC White Paper, p.59.
5. Chen, J., Tan, R., Wang, Y., Xing, G., Wang, X., Punch, B., & Colbry, D. (2012). A High_fidelity Temperature Distribution Forecasting System for Data Centers. IEEE 33rd Real-Time Systems Symposium.
6. Song, Z., Murray, B. T., & Sammakia, B. (2013). Airflow and temperature distribution optimization in data centers using artificial neural networks. International Journal of Heat and Mass Transfer, Vol. 64, 80-90.
7. Song. Z., Murray, B. T., & Sammakia, B. (2014). A dynamic compact thermal model for data center analysis and control using the zonal method and artificial neural networks. Applied Thermal Engineering, Vol. 62, 48-57.
8. Chen, J., Tan, Rui., Xing, G., & Wang, X. (2014). PTEC: A System for Predictive Thermal and Energy Control in Data Centers. IEEE Real-Time Systems Symposium.
9. Estebe, B., LeBot, C., Mancos, J. N., & Arquís, E. (2014). Simulation of a temperature adaptive control strategy for an IWSE economizer in a data center. Applied Energy, Vol. 124, 45-56.

10. Gao, J. (2014). Machine Learning Applications for Data Center Optimization. Google.
11. Ogawa, M. (2015). Cooling Control of Modular Data Center Utilizing Fresh Air in Consideration ICT Equipment Temperature Management and Energy Saving Based on Model Predictive Control. Transactions of the Society of Instrument and Control Engineers, Vol. 51, 561-569.
12. Liu, Q., Ma, Y., Alhussein, M., Peng, L., & Zhang, Yin. (2016). Green data center with IoT sensing and cloud-assisted smart temperature control system. Computer networks, Vol. 101, 104-112.
13. Song, M., Chen, K., & Wang, J. (2017). Numerical Study on the Optimized Control of CRACs in a Data Center Based on a Fast Temperature-Predicting Model. Journal of Energy Engineering, Vol. 143.
14. Lazic, N., Lu, T., Boutilier, C., & Moonkyung, R. (2018). Data center cooling using model-predictive control. Proceedings of the Thirty-second Conference on Neural Information Processing Systems, 3818-3827.
15. McCullock, W. S., & Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity. The bulletin of mathematical biophysics, 5(4), 115-113.
16. Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. Cornell Aeronautical Laboratory, Psychological Review, v65, No. 6, 386-408.
17. Aurelien, G., (2017). Hands-On Machine Learning with Scikit-Learn and TensorFlow. United States of America: O'REILLY, 7-12.
18. Rubio-Herrero, J., Chandan, V., Siegel, C., Vishnu, A., & Vrabie, D. (2017). A Learning Framework for Control-Oriented Modeling of Buildings. 2017 16th IEEE International Conference on Machine Learning and Applications(ICMLA).
19. Muller, A., & Guido, S. (2017). Introduction to machine learning with

- Python. United States of America: O'REILLY, 169-173.
20. Aurelien, G. (2017). Hands-On Machine Learning with Scikit-Learn and TensorFlow. United States of America: O'REILLY, 7-12.
21. Moon, J. W. (2009). ANN-Based Model-Free Thermal Controls for Residential Buildings. Ph.D.diss., University of Michigan.
22. ASHRAE. (2002). ASHRAE Guideline 14. Measurement of Energy and Demand Savings.

<Web Site>

1. George Kamiya. (2019. 11). data centres and data transmission networks. <https://www.iea.org/tcep/buildings/datacentres/>
2. Naomi Xu Elegant. (2019. 11). The Internet Cloud Has a Dirty Secret. <https://fortune.com/2019/09/18/internet-cloud-server-data-center-energy-consumption-renewable-coal/>
3. 배용진, (2019. 11). 한국은 데이터센터 각축장, 글로벌 기업 속속 들어오는 이유. <http://m.pub.chosun.com/mobile/news/view.asp?cate=C01&mcate=M1002&nNewsNumb=20171026426&nidx=26427/>
4. Vigilent. (2019. 11). Dynamic Cooling Management System User Guide for Optimizing Mission Critical Cooling, Version 6.5.1. <http://www.gcss.online/images/products/vigi/Dynamic%20Cooling%20Management.pdf>
5. ABB. (2019. 11). ABB Ability Data Center Automation. https://library.e.abb.com/public/c968b45403cb4495a574388933f0ece8/Data%20Center%20Automation_A4_v1.pdf.
6. Fujitsu. (2019. 11). Data Center Management and Automation Strategic Briefing. <https://sp.ts.fujitsu.com/dmsp/Publications/public/sb-DCMA-en.pdf>.
7. Onionsoftware. (2019. 11). Key Features of The MK119, Unified BMS+DCIM. <http://www.onionsoftware.com/mk119-dcim.html>.

8. Schneider Electric. (2019. 11). Data Center Management.
<https://www.se.com/ww/en/work/solutions/for-business/data-centers-and-networks/cloud-based-dcim-software-dmaas/>
9. ANSYS. (2019. 11). ANSYS Fluent. <https://www.ansys.com/ko-kr/products/fluids/ansys-fluent>.
10. 박응용. (2019. 11). 점프 투 파이썬. <https://wikidocs.net/4307>.
11. ARKEMA, (2019. 11). Forane 134a, Thermodynamic Properties - SI (2010). <https://www.forane.com/export/shared/.content/media/downloads/products-documentations/fluorochemicals/forane-134a-thermodynamic-properties-si.pdf>.

국 문 초 록

컨테인먼트형 데이터센터의 최적 열환경을 위한 적응형 제어알고리즘 개발 및 성능평가

최 영 재

건축학과 건축환경계획전공

중앙대학교 대학원

인터넷 통신량의 증가, 사물인터넷 연결망의 증가 등 데이터 기반 산업에 대한 수요가 증가하며 IT 장비의 통합적 관리 및 유지를 위한 데이터센터에 대한 관심이 급증하고 있다. 데이터센터는 고밀도 에너지 다소비 건물군에 속하며 발열 냉각에 사용되는 에너지가 약 50%를 차지한다. 이에 따라 데이터센터의 에너지 효율을 증가시키기 위해서는 냉방 에너지의 절감이 필수적이다. 따라서 본 연구에서는 컨테인먼트 데이터센터에 대한 최적 실내환경 제공 및 냉방 에너지의 효율적인 운영을 위하여 냉매 유량예측을 기반으로 한 적응형 예측 제어알고리즘을 개발하였다.

대상 시스템은 중앙 냉수식 시스템이 적용된 컨테인먼트이며 냉매 유량 변경을 통해 온도 제어를 실시한다. 데이터 취득 및 성능평가를 위하여 CFD를 통해 2가지 컨테인먼트를 모델링하였으며 실제 데이터센터와의 유사성을 확인하였다. CFD 시뮬레이션을 통해 설정온도, 급기온도, 회수온도, 회수풍량 데이터를 취득한 후 회수풍량이 설정온도가 되기 위한 냉매 유량을

산출하여 데이터셋을 구성하였으며 이를 활용하여 인공지능망을 통한 초기 냉매 유량예측 모델을 개발하였다. 은닉층과 숨겨진 뉴런의 변경을 통해 최적화를 진행하였으며 은닉층 4개, 숨겨진 뉴런 11개 모델이 Cv(RMSE) 0.47%의 우수한 성능으로 최종 예측모델로써 채택되었다.

개발된 예측모델이 새로운 데이터센터 시스템에 적용되어도 최적 냉매 유량을 도출할 수 있도록 오차에 대한 피드백 요소로써 보정인자를 도입하였다. 보정인자는 최적화 결과 $\alpha = 2.0$ 에서 RMSE 1.408로 가장 적은 오차를 나타냈다. 적응형 제어알고리즘은 최종 예측모델과 보정인자를 포함하는 알고리즘으로 성능평가를 위한 컨테이너 모델에서 시뮬레이션이 진행되었다. 제어주기마다 환경 변수 데이터를 취득하여 냉매 유량을 산출하며 해당 냉매 유량이 적용된 다음 제어주기 때의 급기온도와 설정온도의 비교를 통해 새로운 최적 냉매 유량을 산출한다. 새로 산출된 냉매 유량은 이전 제어주기의 환경 변수와 함께 예측모델에 학습되며 위 과정을 반복하여 시스템에 적응한다.

적응형 예측 제어알고리즘은 ON&OFF 시스템 및 보정인자를 제외한 비적응형 제어알고리즘과 비교하여 다양한 환경 시나리오에 대한 적응성 평가를 실시하였다. 그 결과 적응형 예측 제어알고리즘은 모든 시나리오에 대한 평균 RMSE가 0.47로 오차가 가장 낮았으며 학습이 진행됨에 따라 오차가 0에 수렴하는 모습을 나타냈다.

따라서 새로운 환경에 대해 적응형 예측 제어알고리즘은 최적 설정온도를 만족시키는 급기 온도의 제어가 가능했으며 데이터센터 에너지 효율화와 CO₂ 배출 감소를 통한 그린 데이터센터 구축에 핵심 요소로써 적용될 수 있을 것으로 사료된다.

핵심어 : 데이터센터, 최적 열환경 제어, 냉매 유량 예측, 적응형 제어알고리즘

ABSTRACT

Development and Performance Evaluation of Adaptive Control Algorithm for Optimal Thermal Environment in the Containment-type Data Center

Choi, Young Jae

Major in Environmental Design in Architecture
Department of Architecture and Building Science
The Graduate School of Chung-Ang University

Demand for data-based industries, such as the increase in Internet traffic and the rise of IoT connection network, is increasing. For these reasons the data center is highly demanded which provides management and maintenance of IT equipments. The data center belongs to a high density energy consumption building group, and the energy used for cooling systems accounts for approximately 50%. Therefore, it is essential to reduce the cooling energy to increase the energy efficiency of the data center. In this study an adaptive control algorithm based on refrigerant flow predictive model was developed for providing optimal indoor environment and efficient operation of cooling energy for the containment data center.

The target system is a containment model with a central cold water system and temperature control is performed through the refrigerant mass flow rate control. For data acquisition and performance evaluation, two different containments were modeled through CFD and

the feasibility assessment was confirmed. By CFD simulation, setpoint temperature, supply air temperature, return air temperature and return air mass flow rate was obtained. Refrigerant mass flow rate was calculated by these variables and a dataset was constructed. An initial refrigerant flow prediction model was developed through artificial neural network. The optimization was performed by changing the number of hidden layers and hidden neurons. Through the optimization, a final prediction model was adopted which consist of 4 hidden layers and 11 hidden neurons with high performance of 0.47% of Cv(RMSE).

The proposed prediction model is applied to a new data center system, and the correction factor is introduced as a feedback factor for the error to derive the optimal refrigerant flow rate. The correction factor showed the least error with RMSE 1.408 at $\alpha = 2.0$.

Adaptive control algorithm is an algorithm that includes the final predictive model and correction factor. The environmental variables are obtained at each control cycle to calculate the refrigerant mass flow rate, then the new optimal refrigerant mass flow rate is calculated by comparing the supply air temperature with the setpoint temperature during the control cycle. The newly calculated refrigerant mass flow rate is fed to the predictive model along with the environmental variables of the previous control cycle. The Adaptive control algorithm is adapted to the system by repeating the above process.

The adaptive control algorithm was compared with a ON&OFF system and a simple control algorithm which does not include the correction factor. An adaptability assessment was performed for various environmental scenarios. As a result, the adaptive control algorithms had the least error with an average of entire case RMSE

of 0.47, indicating that errors converge with zero as learning progressed.

As a result, the adaptive control algorithm presented the possibility of providing optimal supply air temperature via setpoint temperature. It is highly expected that the adaptive control algorithm being used in the new data center control system and possible to reduce the data center energy as well as CO₂ emission decrease.

Keyword : Data Center, Thermal Environment Optimal Control, Refrigerant Mass Flow Rate Prediction, Adaptive Control Algorithm